Interpreting Emotions in AI

2023105753 이지호

2020102362 이상엽

1.프로젝트 개요

본 프로젝트는 설명 가능하고 신뢰할 수 있는 인공지능(Explainable and Reliable AI) 구축을 목표로, 멀티모달 감정 인식(Multimodal Emotion Recognition) 모델이 언어적 내용(Content)과 비언어적 어조(Tone) 사이에서 어떻게 균형을 맞춰 판단을 내리는지 규명하고자 한다. 특히, 동일한 텍스트라 하더라도 화자의 억양(Prosody)이나 발화 방식에 따라 전달되는 감정이 달라질 수 있다는 점에 주목하여, 텍스트 정보와 오디오 정보가 불일치하거나 상호작용할 때 AI 모델이 감정 판단을 위해 오디오의 어떤 핵심 특징(Key Feature)에 의존하는지를 구체적으로 설명하는 데 초점을 맞추었다.

이를 위해 본 프로젝트에서는 IEMOCAP 데이터셋을 활용하여 텍스트와 오디오를 결합한 멀티모달 모델을 구축하고, 두 가지 핵심적인 분석 방법을 수행한다. 첫째, 특정 음향 특징(Pitch, Energy)을 제거(Masking)했을 때 모델의 성능 변화를 측정함으로써 각 모달리티의 기여도를 정량적으로 산출한다. 둘째, 텍스트가 오디오 정보를 쿼리(Query)하는 과정을 시각화하는 Cross-Attention 분석을 통해, 언어적 의미와 음향적 특징 간의 정렬(Alignment) 패턴 및 가중치가 집중되는 구간을 면밀히 파악한다.
궁극적으로 본 연구는 고각성 감정(분노, 행복)에서는 청각 정보에, 중립 감정에서는 텍스트 정보에 의존하는 인간의 감정 지각 방식과 AI 모델의 판단 메커니즘 간의 유사성을 입증하는 것을 목표로 한다. 나아가 Pitch Contour의 급격한 변화 구간이나 주파수 에너지 분포 등 물리적 특징에 기반하여, AI가 왜 특정 감정으로 판단했는지에 대한 '설명 가능한 근거'를 제시함으로써 감정 인식 모델의 신뢰성을 제고하고자 한다.

---

2. 데이터 이해 및 전처리

2.1 Dataset

데이터셋: IEMOCAP (Interactive Emotional Dyadic Motion Capture Database)
감정 분류: 분노(ANG), 행복(HAP), 중립(NEU), 슬픔(SAD)

2.2 전처리

(1) 입력 형식 통일

서로 다른 규격의 원본 데이터를 모델이 처리 가능한 형태로 통일하였다

• **오디오**: Hugging Face datasets 라이브러리를 통해 로드하고 16kHz 샘플링 레이트로 변환(cast)한다. 원본 오디오 배열은 배치 내 입력 크기의 일관성을 보장하기 위해 고정된 길이(MAX_AUDIO_LEN * 16000)에 맞춰 패딩(padding)하거나 자른다(truncate).
• **텍스트**: RobertaTokenizer (roberta-base)를 사용하여 토큰화 하였다. 인코더가 예상하는 입력 형식에 맞추기 위해 문장을 고정된 시퀀스 길이(MAX_TEXT_LEN)로 패딩하거나 자른다.

(2) 공간 정규화 (CenterCrop 336×336)

Wav2Vec2 인코더가 입력 신호로부터 특징(Feature)을 안정적으로 추출할 수 있도록 스케일링을 적용하였다. 원본 오디오 파형(Raw Waveform)에 Min-Max 정규화를 적용하여, 모든 신호 값을 [-1, 1] 범위 내로 조정함으로써 데이터 분포의 편차를 줄이고 모델 수렴을 돕도록 설계하였다.

(3) 텐서 변환

PyTorch 기반의 연산을 위해 데이터를 텐서 형태로 변환하고, 유효 데이터 식별을 위한 마스크를 생성하였다. 오디오의 데이터 타입은 torch.float32, 감정 레이블(Labels)은 torch.long으로 변환하였다. 가변 길이의 오디오 입력을 어텐션 메커니즘(Attention Mechanism)이 올바르게 처리할 수 있도록, 유효 구간은 1, 패딩 구간은 0으로 마킹한 '오디오 마스크(Audio Mask)'를 생성하였다.

(4) 정규화

본 모델의 사전 학습 분포와 입력 데이터의 분포를 일치시키기 위해 정규화를 수행하였다. DINOv2 사전 학습된 모델의 기준에 맞춰 각 채널별 평균(Mean)과 표준편차(Std)를 적용, 정규화를 수행함으로써 조명이나 색상 편차로 인한 특징 왜곡을 방지하였다.

- mean = [0.48145466, 0.4578275, 0.40821073]
- std = [0.26862954, 0.26130258, 0.27577711]

(5) 배치 및 디바이스 매핑

학습 효율성을 높이기 위해 DataLoader를 활용한 배치 구성을 수행함. torch.utils.data.DataLoader를 사용하여 샘플들을 배치(크기는 config.py에 정의됨)로 그룹화하였다. 순서에 의한 편향(order bias)을 방지하기 위해 훈련 세트에 셔플(shuffling)을 활성화하였다. 장치 매핑(Device Mapping): 코드는 사용 가능한 하드웨어 가속기를 자동으로 감지함. 우선순위: MPS (Apple Silicon) > CUDA (NVIDIA GPU) > CPU. 학습 루프 내에서 각 배치 구성 요소(input_ids, attention_mask, audio, audio_mask, labels)는 모델에 전달되기 전 .to(device)를 사용하여 선택된 장치로 명시적으로 이동됨.

(6) 최종 입력 형태 (Final Input Shape)

최종 텐서는 (Batch_Size, Channels, Height, Width) 형태의 정규화된 float32 타입으로 구성되며, 이를 통해 모델의 인코더가 즉시 처리 가능한 최적의 상태를 갖추게 된다. **텐서 크기**: (1, 3, 336, 336) (시각/스펙트로그램 입력의 경우)

---

3. 모델 구조 및 학습 (Model Structure and Training)

3.1 모델 구조

텍스트와 오디오 특성을 융합하는 멀티모달(Multimodal) 아키텍처다.

3.1.1 텍스트 모델

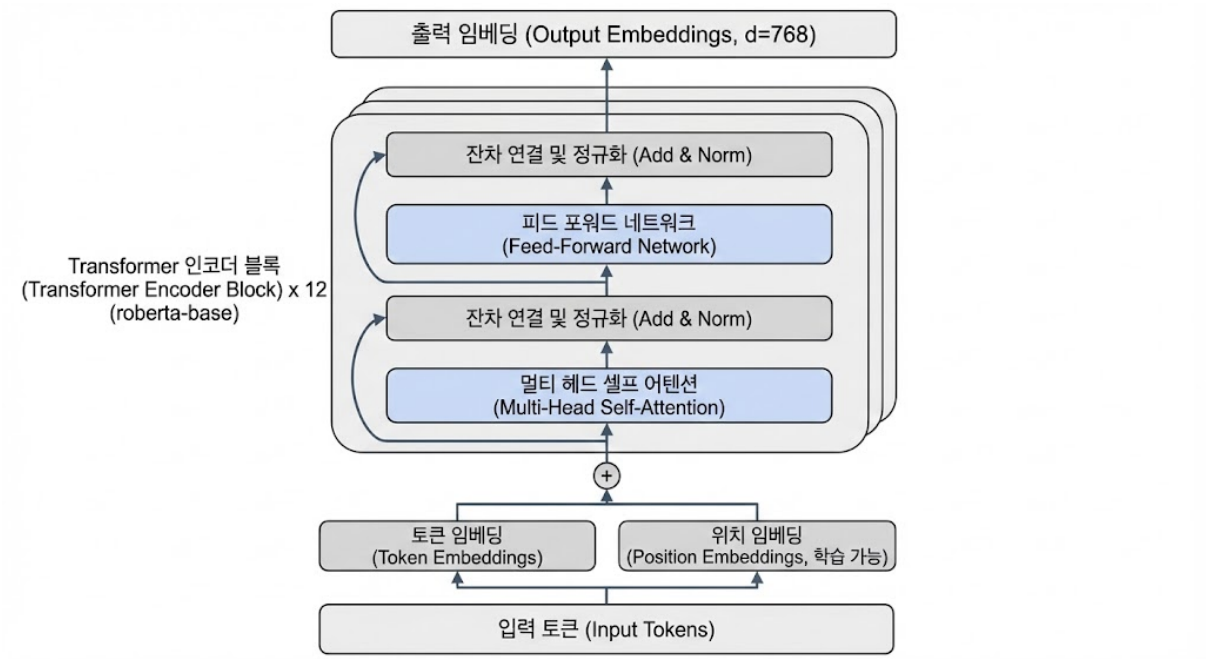

- **백본**: RobertaModel (roberta-base)
- **차원**: 768
- **기능**: 스크립트(Transcript)에서 의미론적(Semantic) 특성을 추출한다.

3.1.2 오디오 모델

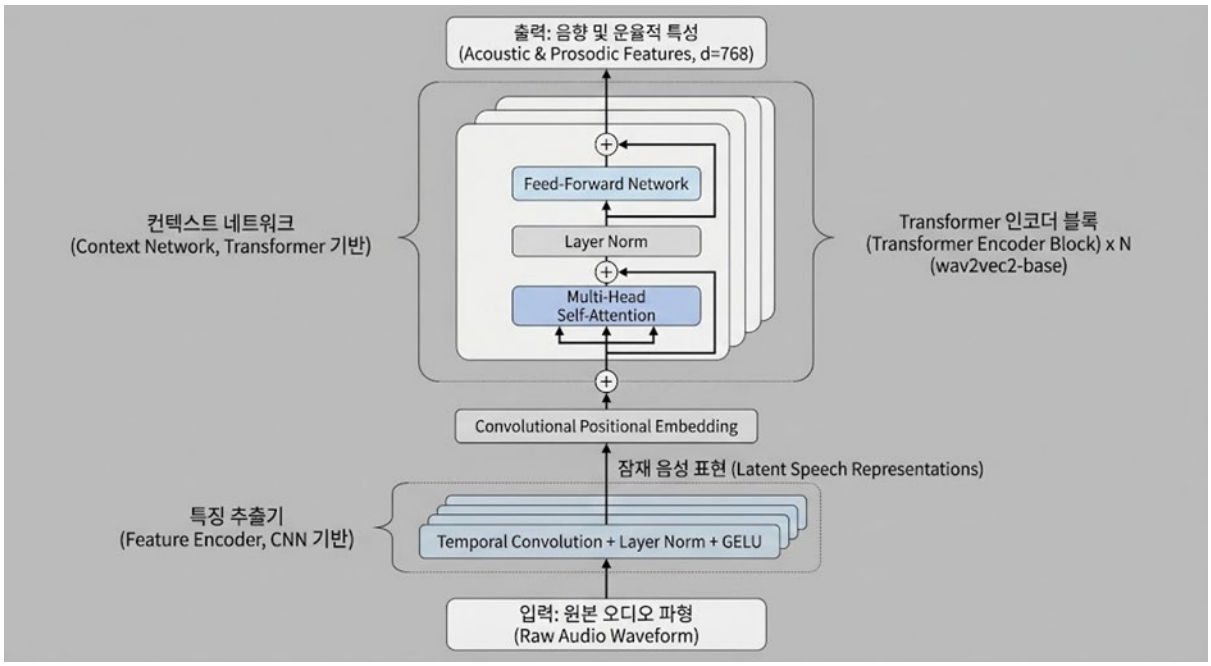

- **백본**: Wav2Vec2Model (facebook/wav2vec2-base-960h)
- **차원**: 768
- **기능**: 원본 파형(Raw Waveform)에서 음향 및 운율적 특성을 추출한다.
- **프로젝션**: 선형 레이어(Linear Layer)를 통해 오디오 특성을 텍스트 차원과 일치시킨다 (768 -> 768).

- **Feature Encoder (CNN):** 파형의 진폭(Amplitude)을 분석하여 소리의 강도인 **Energy 정보**를 1차적으로 포착한다.

- **Context Network (Transformer):** CNN 출력의 시간적 흐름을 학습하여, 주파수의 변동 패턴인 Pitch Contour(억양)와 같은 운율적 정보를 768차원 벡터 공간에 내재화(Encoding)한다. 즉, Wav2Vec2의 최종 출력 벡터(d=768)는 명시적인 숫자는 아니지만, "이 구간에서 목소리가 높고(High Pitch) 크다(High Energy)"는 정보를 고차원 벡터의 형태로 함축하고 있다.

3.1.3 교차 어텐션 (Cross Attention)

멀티모달 융합을 위해 텍스트가 오디오 정보를 능동적으로 탐색(Querying)하는 Cross-Attention 구조를 설계하였다. 이 과정에서 Pitch와 Energy 정보가 반영되는 원리는 다음과 같다.

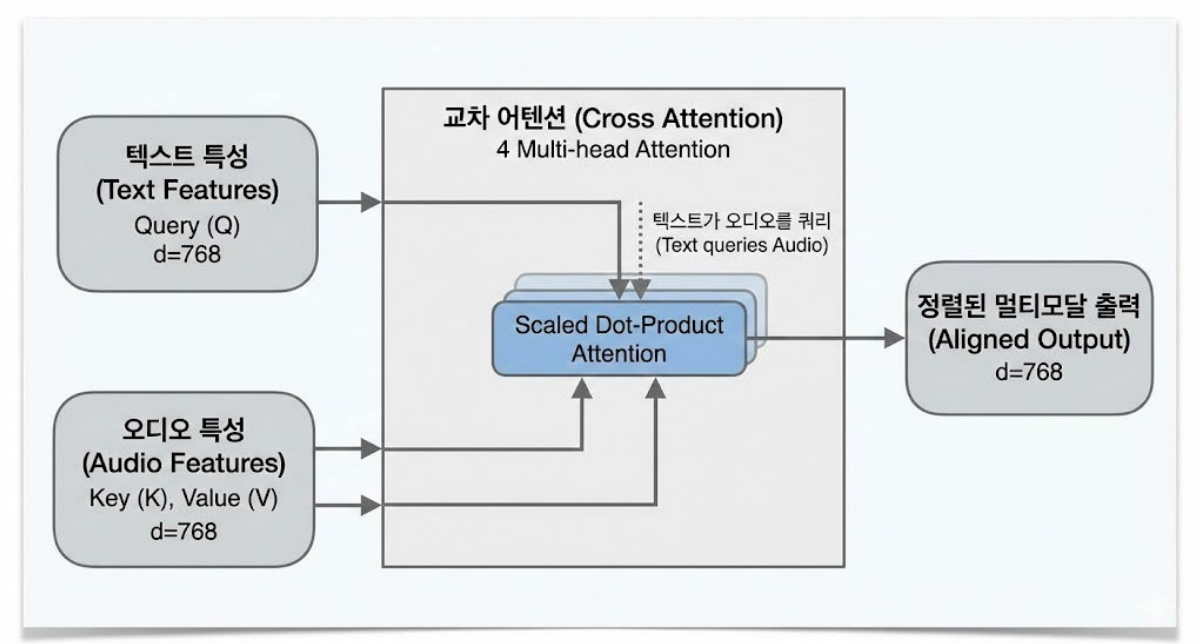

- **메커니즘**: 텍스트가 오디오를 쿼리(Query)하는 방식입니다.
- **Query**: 텍스트 특성
- **Key/Value**: 오디오 특성
- **Heads**: 4 Multi-head Attention
- **목적**: 특정 텍스트 토큰에 해당하는 오디오 프레임을 식별하여, 운율과 의미적 내용을 효과적으로 정렬하기 위해서다.

작동 원리 :

- 정보의 탐색: 텍스트의 각 토큰(Query)은 감정 판단에 필요한 단서를 찾기 위해 오디오의 전체 시퀀스(Key)를 훑는다.

- Pitch/Energy 기반 정렬 (Alignment): 학습 과정에서 모델은 "강한 감정을 나타내는 단어(Q)는 높은 Pitch나 강한 Energy를 가진 오디오 구간(K)과 연관된다"는 패턴을 학습한다.

- 가중치 부여 (Attention Score): 예를 들어, 사용자가 화를 내는 텍스트 구간에서 오디오 벡터(K)가 '급격한 Pitch 상승' 정보를 담고 있다면, 모델은 두 정보의 연관성을 높게 평가하여 해당 구간에 높은 Attention 가중치를 부여한다.

모델의 핵심 작동 원리: 특징의 내재화와 참조

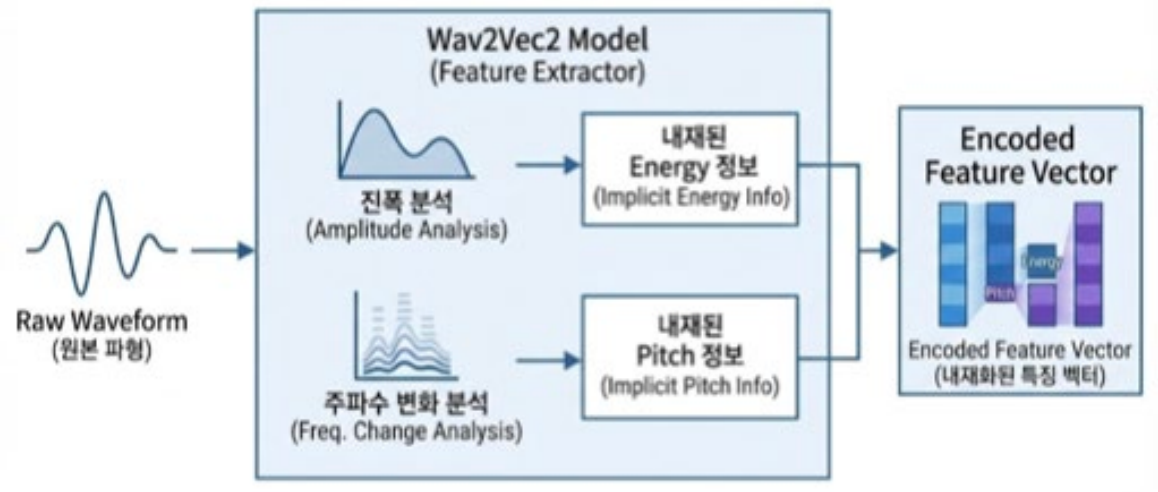

Pitch와 Energy 값을 따로 계산해서 넣은 것이 아니라, Wav2Vec2 모델을 사용하였다. 이 모델이 Raw Waveform(원본 파형)을 입력받아 벡터를 만들 때, 파형의 진폭에서 Energy를, 주파수의 시간적 변화에서 Pitch 정보를 스스로 학습해 벡터 안에 내재화(Encoding) 시킨다. Cross-Attention 단계에서는 텍스트(Query)가 이 오디오 벡터(Key)를 참조하는데, 이때 '벡터 값이 급격히 변하는 구간(즉, Pitch나 Energy가 높은 구간)'에 Attention 점수가 높게 찍히도록 학습된다. 결과적으로 모델이 Pitch와 Energy의 변화를 보고 감정을 판단하게 된다.

3.1.4 분류기 (Classifier)

• **구조**:
– Linear (768 -> 256)
– ReLU 활성화 함수
– Dropout (안정성을 위해 0.0 설정)
– Linear (256 -> 4) (출력 클래스: ANG, HAP, NEU, SAD)

3.2 학습 방법

• **손실 함수**: 교차 엔트로피 손실 (Cross Entropy Loss)
• **옵티마이저**: AdamW
• **전략**: 감정 인식 작업에 적응하도록 두 인코더 모두 미세 조정(Fine-tuning, Unfrozen)하였다.

4. 실험 및 결과

4.1 음향 특징 탐색적 데이터 분석 (Acoustic Feature EDA)

4.1.1 Pitch 분포 분석

Pitch는 음성 신호에서 감정의 각성도(arousal)를 나타내는 핵심 음향 특징이다. 전체 데이터셋에서 각 발화의 평균 Pitch를 추출하여 감정별 분포를 분석하였다.

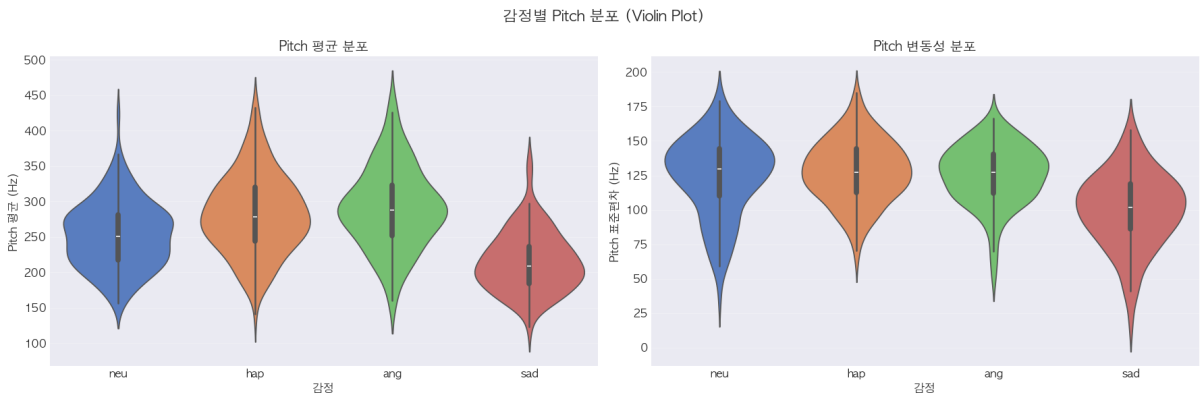

분석 포인트:

- **ANG (분노)**: 높은 구간(200~300 Hz)에 편중, 꼬리가 400 Hz까지 길게 뻗어있음
- **HAP (행복)**: 분노보다 약간 낮지만 여전히 높은 주파수 대역(180~250 Hz)에 분포
- **NEU (중립)**: 중간 대역(150~200 Hz)에 비교적 좁게 집중된 분포
- **SAD (슬픔)**: 가장 낮은 구간(100~180 Hz)에 분포하며, 분포 폭이 좁고 집중적임

해석: 감정별 평균 Pitch 분포를 violin plot으로 분석한 결과, 분노와 행복은 평균적으로 높은 pitch를, 슬픔은 가장 낮은 pitch를 보였다. 그러나 각 감정의 pitch 분포가 상당 부분 겹쳐 있어 pitch만으로는 감정을 명확히 구분하기 어려웠다. 이는 pitch가 의미 있는 단서이지만 단독 feature로는 분류 성능이 제한적임을 시사하며, 다른 feature를 복합적으로 활용할 필요성을 보여준다.

4.1.2 Energy (RMS) 분포 분석

음성의 에너지(진폭)는 감정의 강도(intensity)를 나타내는 또 다른 핵심 특징이다. RMS(Root Mean Square) 에너지를 추출하여 감정별 분포를 분석하였다.

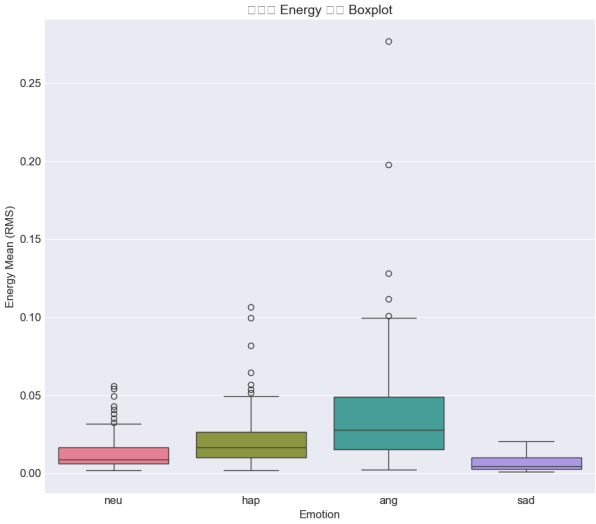

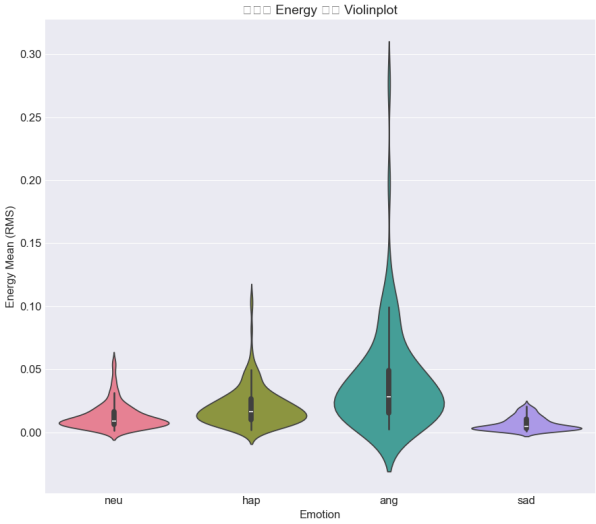

분석 포인트:

- **ANG (분노)**: 가장 높은 에너지 (평균 0.0521), 분포 폭이 넓음
  1. 큰 목소리, 강한 발화 강도 반영
  2. Violin 형태가 위쪽으로 치우치고 두꺼움
- **HAP (행복)**: 중상위 에너지 (평균 0.0438)
  1. 분노보다는 낮지만 여전히 높은 에너지
  2. 활기찬 발화 특성
- **NEU (중립)**: 중간 에너지 (평균 0.0342)
  1 .보통 크기의 목소리
  2. 분포가 비교적 좁고 일정
- **SAD (슬픔)**: 가장 낮은 에너지 (평균 0.0265), 분포 폭이 좁음
  1. 작고 약한 목소리
  2. Violin 형태가 아래쪽에 집중되고 얇음

해석: RMS 에너지 분석에서는 감정에 따라 음성 강도의 평균과 분산에서 차이가 나타났다. 분노는 강한 발성으로 인해 가장 높은 평균 energy와 표준편차를 보였고, 슬픔은 전반적으로 조용하게 발화되며 가장

낮은 수치를 나타냈다. 이와 같은 energy 차이는 감정의 각성도를 반영하며 pitch와 함께 복합적으로 작용할 때 감정 구분에 유효하게 작용한다.

4.2 Feature Masking 실험

4.2.1 실험 설계

텍스트와 오디오 정보의 상대적 중요도를 정량적으로 평가하기 위해 Feature Masking 실험을 수행하였다. 본 실험에서는 특정 음향 특징(Pitch, Energy)을 의도적으로 제거하거나 마스킹하여 모델 성능의 변화를 측정한다.

음향 특징 추출 방법:

본 실험에서는 Librosa 라이브러리를 사용하여 음성 신호로부터 pitch와 energy를 추출하였다.
• **Pitch**: Probabilistic YIN (pyin) 알고리즘을 사용하여 추출하였다. 이 방법은 일반적인 자기상관법보다 잡음에 강건하며, 무성음 구간에서는 NaN을 반환한다. 각 발화의 평균 pitch는 np.nanmean을 사용하여 무성음 구간을 제외하고 계산하였다.
• **Energy**: RMS(Root Mean Square) 방식으로 각 프레임의 진폭을 계산하였다. RMS는 인간이 인지하는 음량(loudness)을 효과적으로 나타내는 지표이다.

Feature Masking 방법:
특정 음향 특징이 감정 인식에 미치는 영향을 분석하기 위해, 각 특징을 평균값으로 대체하는 방식으로 masking을 수행하였다.

• **Pitch Masking**: Parselmouth의 PSOLA(Pitch-Synchronous Overlap and Add) 기법을 사용하여 pitch를 평균값으로 고정시켰다. 이는 원본 음성의 운율(prosody) 변화를 제거하여 단조로운 억양으로 만든다. Pitch를 0Hz로 설정하면 침묵이나 저음 잡음이 발생하므로, 평균 pitch(예: 150Hz)로 설정하여 음성 자체는 유지하되 억양 변화만 제거하였다.

• **Energy Masking**: Hilbert Envelope를 사용하여 음성의 다이내믹 레인지(강약)를 정규화하였다. 모든 프레임의 에너지를 평균 진폭으로 고정시켜 음량 변화를 제거하였다. Energy를 0으로 설정하면 완전한 침묵이 되므로, 평균 에너지 값으로 설정하여 발화는 유지하되 강약의 변화만 제거하였다.

실험 조건:
• **Baseline**: 텍스트 + 오디오 (전체 특징 사용)
• **Condition 1**: Pitch Masking - Pitch 관련 특징을 제거하거나 0으로 대체
• **Condition 2**: Energy Masking - Energy 관련 특징을 제거하거나 0으로 대체

• **Condition 3**: 텍스트 전용 - 오디오 특징 전체 제거
• **Condition 4**: 오디오 전용 - 텍스트 특징 제거
• **Condition 5**: Pitch+Energy Masking - 두 특징 모두 제거

평가 지표:
• Accuracy: 전체 정확도
• Weighted F1-Score: 클래스 불균형을 고려한 F1-Score
• 감정별 F1-Score: 각 감정(ANG, HAP, NEU, SAD)에 대한 분류 성능

4.2.2 실험 결과

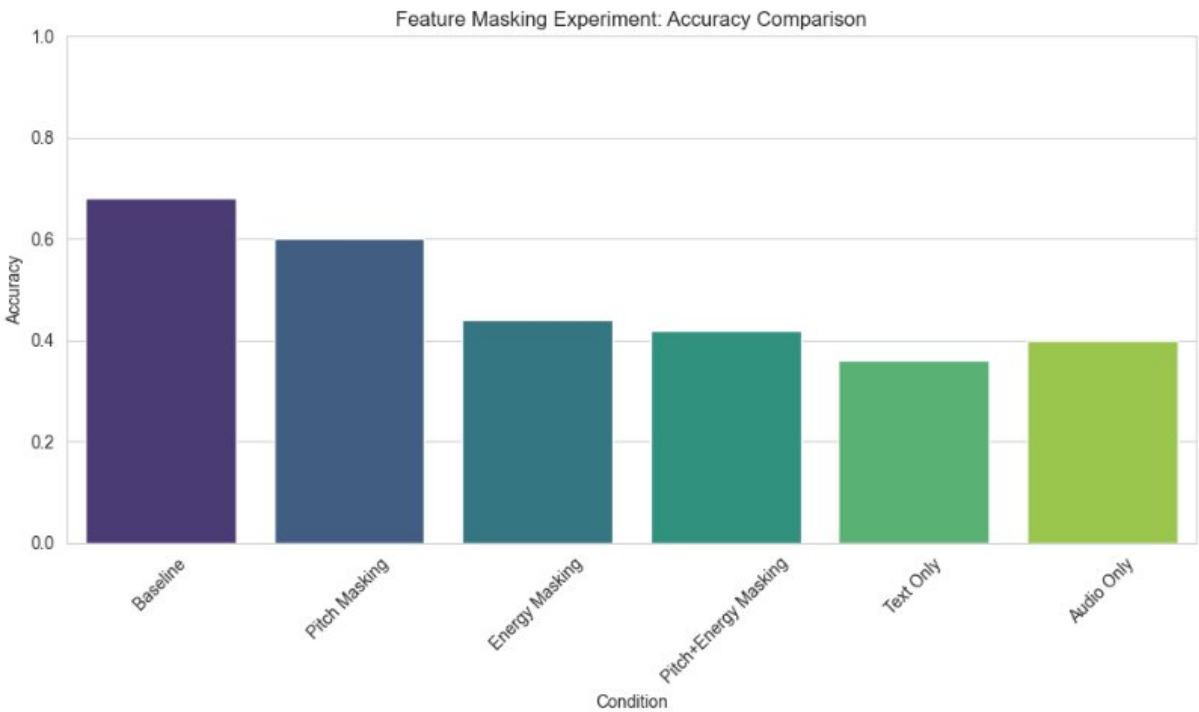

Feature Masking 실험 결과를 분석한 결과, Pitch를 masking했을 때보다 energy를 masking했을 때 accuracy가 급격히 떨어지는 현상이 발견되었다. 이는 본 모델이 energy 정보를 감정 분류에 더 중요한 feature로 활용하고 있음을 의미한다.

4.2.3 감정별 성능 분석

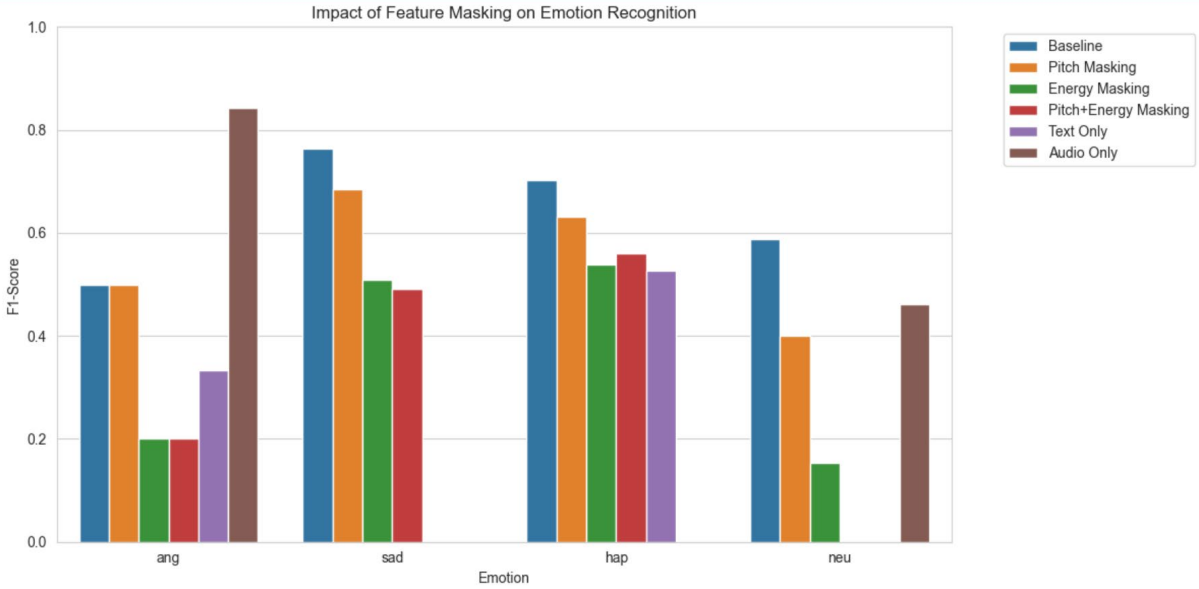

분노 (Angry): Baseline F1 score가 0.5 정도인데 반해 Audio only 조건에서 F1 score가 0.842로 크게 향상되었다. 반면 energy를 제거하면 F1 score가 0.2 부근까지 급락했다. 이는 분노가 pitch와 energy 같은 음향 정보에 매우 민감하며, 텍스트는 오히려 혼동을 주는 noise 역할을 했을 가능성이 있음을 보여준다. 모델은 억양만으로도 분노를 정확히 인식할 수 있었다.

행복 (Happy): 행복은 반대로 텍스트에 강하게 의존하는 감정이다. Audio only 조건에서 F1 score가 0으로 분류가 완전히 실패했고, baseline에서는 약 0.7로 높은 성능을 유지했다. 이는 pitch와 energy 정보가 angry와 겹칠 수 있어 억양만으로는 감정 구분이 어렵다는 것을 보여준다.

슬픔 (Sad): 슬픔은 텍스트에도 의존하지 않고, 오디오만으로도 부족하며, 억양의 높이(Pitch)와 세기(Energy), 텍스트가 함께 작동해야 감정으로 인식될 수 있다. 특히 Energy에 가장 강하게 의존하는 감정이다. Pitch를 제거해도 어느 정도 분류는 가능하지만, Energy가 제거되면 성능이 급격히 떨어졌다.

중립 (Neutral): 중립 감정은 감정이 없음이라는 특성상 다른 감정보다 뚜렷한 감정 신호가 없다. 따라서 pitch, energy가 제거되거나 text만 사용했을 경우, 모델이 중립 감정을 구별하지 못하고 다른 감정과 혼동하게 된다. 이는 음성에서의 미묘한 억양 차이 자체가 모델이 인식하는 유일한 단서임을 시사한다.

일부 조건에서 F1 score가 0이 나오는 현상이 발생했는데, 이는 feature masking으로 인해 특정 감정의 고유한 특징이 제거되면서 모델이 해당 감정을 전혀 예측하지 못하게 되었기 때문이다. EDA에서 확인했듯이 감정별 feature 분포가 부분적으로 겹치는데, masking으로 남은 feature만을 이용하게 되면 유사한 feature 분포를 가진 다른 감정으로 오분류되는 경향이 나타난다.

4.2.4 Cross-Attention 분석

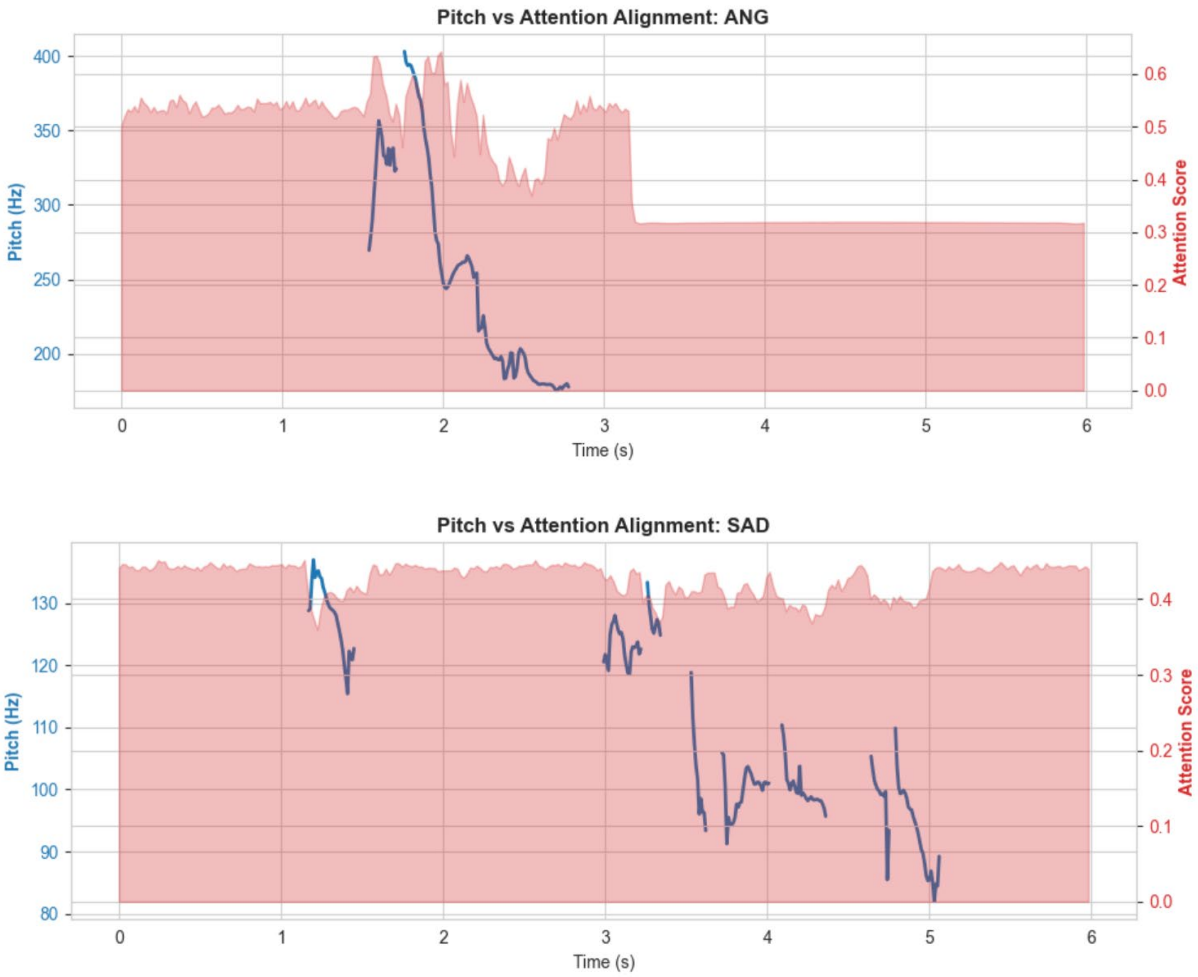

[Figure 1]

Feature Masking 실험과 함께, 모델 내부의 Cross-Attention 메커니즘을 분석하여 텍스트와 오디오 정보가 어떻게 상호작용하는지 확인하였다.

Attention Score 계산:

모델은 Scaled Dot-Product Attention을 사용하여 attention score를 계산한다. Cross-Attention layer는 텍스트 feature를 query로, 오디오 feature를 key 및 value로 사용하여 각 텍스트 토큰이 오디오의 어느 시점을 중요하게 참조하는지를 학습한다. Attention score는 다음 수식으로 계산된다

$$\text{Attention}(Q, K, V) = \text{softmax}(QK^T / \sqrt{d_k}) \times V$$

여기서 Q는 텍스트 encoder의 출력 feature, K와 V는 오디오 encoder의 출력 feature이며, d_k는 feature dimension(본 모델에서는 768)이다. Softmax를 통해 정규화된 attention weights는 0과 1 사이의 값으로, 각 텍스트 토큰이 각 오디오 프레임에 부여하는 가중치를 나타낸다.

본 실험에서는 훈련된 모델의 forward pass 중 cross-attention layer에서 attention weights를 추출하여 분석하였다. Multi-head attention의 경우 여러 head의 평균값(mean(dim=0))을 계산하여 전체적인 attention 패턴을 파악하였다.

Pitch-Attention 시간축 정렬 분석:

Attention weights가 pitch 변화 패턴과 어떤 관계가 있는지 분석하기 위해 Dual-Axis Time Series Chart를 작성하였다. Attention weights를 텍스트 차원으로 합산하여 각 오디오 시점별 전체 attention 가중치를 계산하고, Parselmouth 라이브러리를 사용하여 추출한 pitch 값과 함께 이중 y축 그래프로 표현하였다.

[Figure 1]은 분노(ANG)와 슬픔(SAD) 감정의 Pitch-Attention Alignment를 보여주는 Dual-Axis Time Series Chart이다. 파란색 선은 시간에 따른 pitch 변화를, 빨간색 영역은 각 시점에 대한 attention score를 나타낸다.

분노 (ANG) 패턴: 분노 발화에서는 pitch가 급격히 변화하는 구간(특히 1.5~2.0초 구간에서 350Hz → 250Hz로 급락)에서 attention score가 0.6 이상으로 상승하였다. 이는 모델이 억양의 급격한 변화를 감정 판단의 중요한 단서로 활용함을 의미한다. 모델은 pitch의 급변 지점을 강하게 참조함으로써 분노라는 감정의 격양된 특성을 포착하고 있다.

슬픔 (SAD) 패턴: 반면 슬픔 발화는 pitch가 130Hz 근처에서 거의 평탄하게 유지되며, attention score가 특정 구간에 집중되지 않고 전체에 걸쳐 0.3~0.4 수준으로 고르게 분산되었다. 이는 모델이 특정 변화 지점보다는 전반적으로 낮고 평탄한 억양 패턴 자체를 슬픔의 단서로 인식함을 보여준다. 슬픔의 경우 단일 시점의 변화보다는 전체 발화에 걸친 억제된 억양이 핵심 특징이 된다.

---

5. 인간과 AI 모델의 연결성

본 프로젝트의 실험 결과, AI 모델이 감정을 판단하는 방식은 기존 학계에서 규명된 인간의 인지 방식과 ‘Feature 중요도(Priority)’ 면에서 명확한 차이를 보였다. 인간은 Pitch의 '맥락적 흐름(Contour)' 중심 (이론적 근거) 기존 Scherer의 구성 요소 프로세스 모델(Component Process Model) 및 심리음향학 연구 에 따르면, 인간은 감정 각성(Arousal)을 감지하는 초기 단계에서 운율(Prosody)과 Pitch(억양)의 역할을 가장 중요하게 활용한다. 즉, 인간은 단순히 소리의 크기나 높낮이뿐만 아니라, 말의 흐름과 억양의

미세한 곡선(Intonation)을 통해 감정의 뉘앙스를 파악하는 'Pitch 우위성을 보인다. AI 모델은 nergy 및 '통계적 수치(Statistics)'에 대한 편향 반면, 본 연구의 Feature Masking 실험 결과는 AI 모델이 인간과는 다른 양상을 보임을 증명하였다. 특히 Anger 감정 분류 시, 인간의 핵심 인지 요소인 Pitch를 제거했을 때보다 Energy를 제거했을 때 모델의 정확도가 더 급격히 하락하였다. 이는 AI 모델이 인간처럼 '시간에 따른 억양의 흐름'을 이해하기보다는, '소리의 강도(Energy)'나 '주파수의 물리적 절댓값'과 같은 단순하고 강렬한 통계적 특징에 과도하게 의존하고 있음을 시사한다. 결과적으로 AI는 데이터 학습을 통해 높은 성능을 내더라도, 인간의 직관적인 감정 인지 프로세스와는 다른 방식으로 작동할 수 있다는 한계가 확인되었다.

---

6. 한계점 및 향후 개선 방향

6.1. 성능적 한계: 특정 감정(Sad, Neutral)의 오분류 및 F1-Score 편차

본 연구의 멀티모달 모델은 텍스트와 오디오 정보를 효과적으로 결합하여 전반적으로 준수한 성능을 입증하였으나, 감정별 인식 성능의 편차는 여전히 해결해야 할 과제로 확인되었다. 구체적으로 살펴보면, 분노(Anger)나 행복(Happiness)과 같은 고각성 감정의 경우 Pitch와 Energy의 변화가 뚜렷하게 나타나 높은 분류 정확도를 기록하였다. 반면, 슬픔(Sad)이나 중립(Neutral)과 같은 저각성 감정군은 음향적 특징(Feature)의 변동성이 적어 오디오 정보 단독으로는 명확한 구분이 어려운 것으로 나타났다. 특히 Feature Masking 실험 결과, Neutral 감정은 미세한 음향 정보가 제거되었을 때 F1-Score가 급격히 하락하는 경향을 보였는데, 이는 모델이 미세한 감정의 차이를 안정적으로 판별하기 위해서는 텍스트 문맥(Context)이나 다중 모달리티의 복합적인 정보 결합이 필수적임을 시사한다.

6.2. 데이터의 한계 및 일반화 문제

실험에 활용된 IEMOCAP 데이터셋은 전문 배우들이 통제된 환경에서 연기한 데이터라는 특성상 몇 가지 내재적 한계를 지닌다. 우선, 실제 일상 대화 환경에서는 각종 소음이 혼재하거나 감정 표현이 모호한 경우가 빈번하나, 정제된 연기 데이터는 이러한 현실적 복잡성을 온전히 반영하지 못한다는 점에서 자연성의 부족이 지적된다. 아울러 데이터의 대부분이 짧은 발화(Utterance) 단위로 구성되어 있어, 긴 호흡의 대화 맥락에서 발현되는 장기적인 운율 패턴(Long-term Prosody)이나 감정의 동적인 전이 과정을 심도 있게 분석하는 데에는 물리적인 제약이 따랐다.

6.3. 향후 연구 방향

상기한 한계점을 극복하고 AI 모델의 감정 인지 메커니즘을 인간의 방식에 더 가깝게 발전시키기 위해, 본 연구는 다음과 같은 후속 연구 방향을 제언한다.

우선, 본 연구에서 확인된 AI 모델의 'Energy 편향 현상'에 대한 근본적인 원인 규명이 선행되어야 한다. 이러한 편향이 모델의 구조적 특성에서 기인한 것인지, 혹은 학습 데이터셋 자체의 특성에서 비롯된 것인지 명확히 파악하기 위해, Scherer의 구성 요소 프로세스 모델(Component Process Model) 등 검증된

인지과학 이론을 바탕으로 한 심층적인 분석이 요구된다. 나아가 단순한 음향 특징(Acoustic Feature)의 통계적 수치 학습을 넘어, 인간과 같이 운율적 맥락(Prosodic Context)과 억양 곡선(Contour)의 형태를 핵심 정보로 인지할 수 있도록 '운율 인식 모델링(Prosody-Aware Modeling)'으로의 구조적 개선이 필요하다. 구체적인 방안으로는 Pitch의 동적인 시간적 변화 추이를 정교하게 포착할 수 있도록 시계열 특화 레이어를 강화하거나, 학습 과정에서 Prosody 정보를 명시적으로 주입하여 억양의 흐름을 강조하는 기법의 도입을 고려할 수 있다.