Explaining Multimodal Emotion Recognition: How Do AI Models Balance Content and Tone?

이지호 이상엽

Research objective

연구 목표	텍스트-오디오 정보 불일치 시, 멀티모달 AI가 감정 판단을 위해 오디오의 어떤 핵심 피쳐를 보고 판단하는지 설명한다.
핵심 방향	• **Feature Masking 기여도 평가** 특정 음향 특징 (Pitch,Energy)을 제거(Masking)했을 때의 모델 성능 변화를 측정하여, 각 모달리티의 핵심 기여도 산출 • **Multimodal Cross-Attention 분석** 텍스트가 오디오를 쿼리하는 과정을 시각화하여, 언어적 의미와 음향적 특징(운율)간의 정렬(Alignment) 패턴 및 가중치 집중 구간 분석
Target OutCome	• **인간 인지 매커니즘과의 일치성 검증** 고각성 감정(분노, 행복)에서는 청각 정보에, 중립 감정에서는 텍스트 정보에 의존하는 인간의 감정 지각 방식과 AI 모델의 유사성 입증 • **설명 가능한 감정 판단 근거 제시** Pitch Countour의 급변 구간 및 주파수 에너지 분포 등 물리적 특징에 기반한 AI의 감정 판단 근거 확보

Research objective

1. 모호한 문장 실험 (불필요)

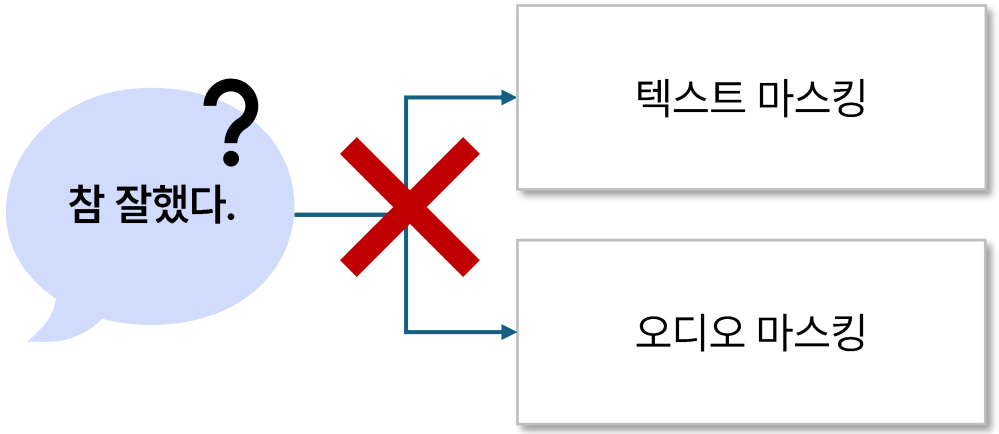

모호한 문장에 대해서는 당연히 오디오가 필요했기에,
텍스트랑 오디오를 마스킹 하는 것이 의미가 없음

2. 텍스트 Fix 실험 (분석)

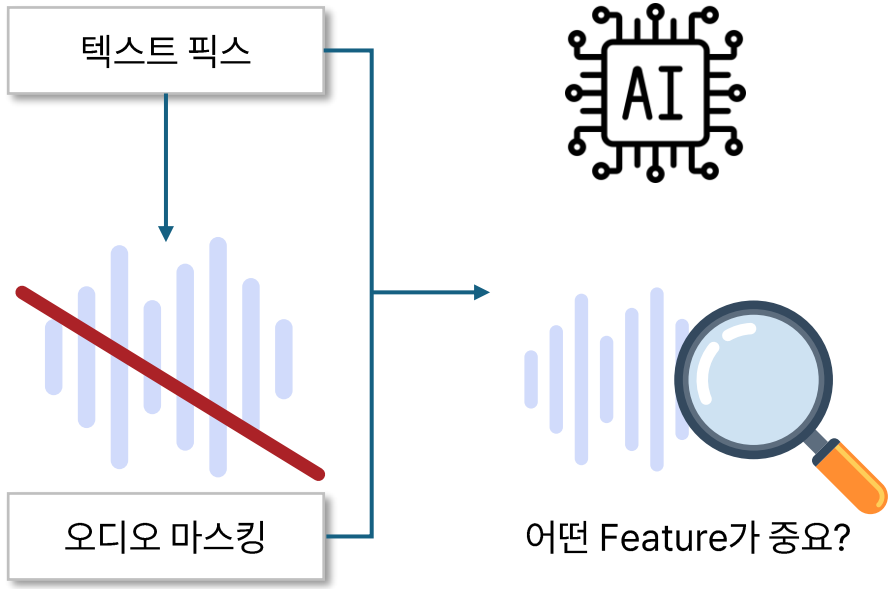

오디오에서 어떤 피쳐를 바탕으로 인공지능은
판단하는지로 실험 범위를 좁혔음

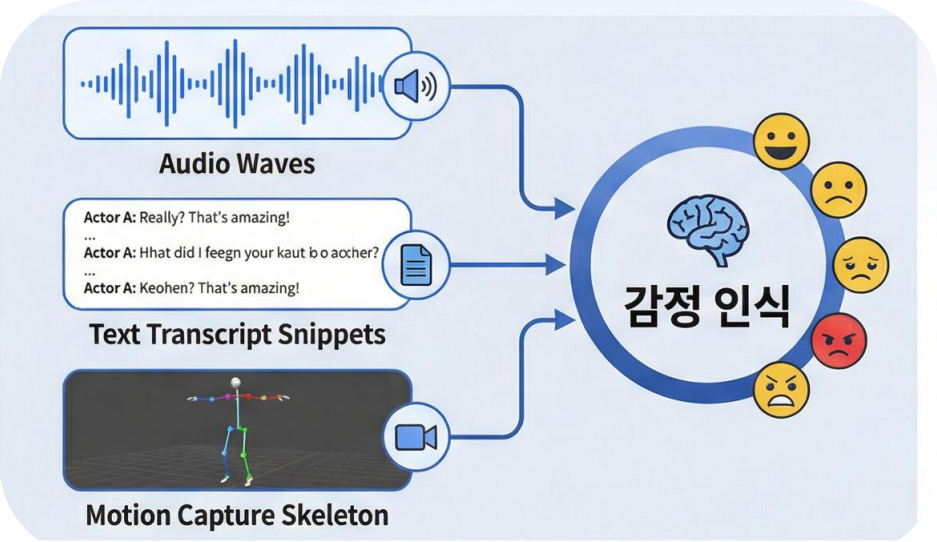

1. Dataset 개요

표준 벤치마크: IEMOCAP

구축: 전문 배우 10명, 2인 1조

분량: 약 12시간의 음성/텍스트 데이터

2. 선정근거

상호작용 포함

자연스러운 감정 변화

다중 모달리티 (음성,텍스트 포함)

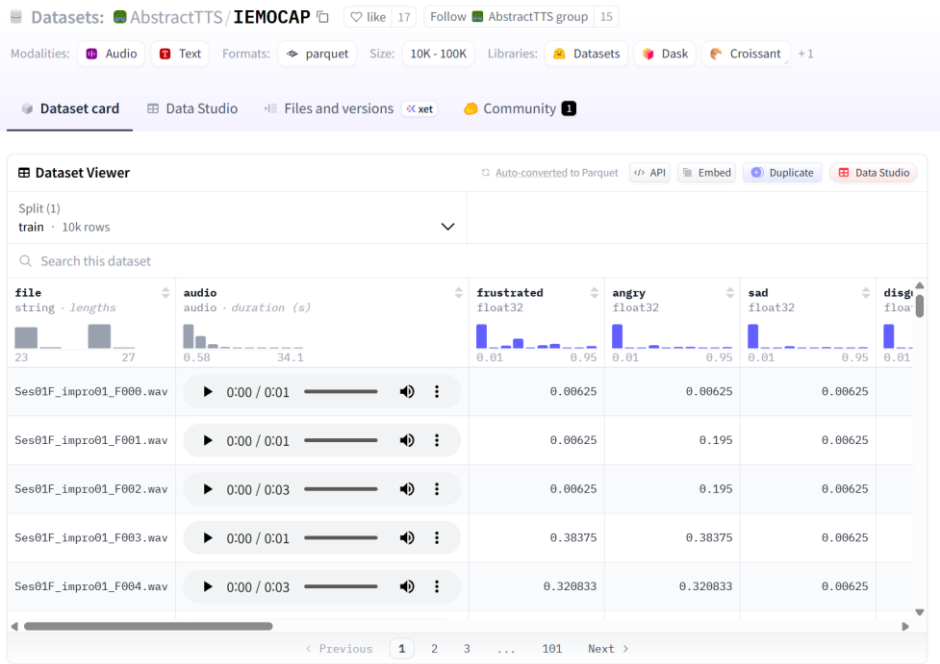

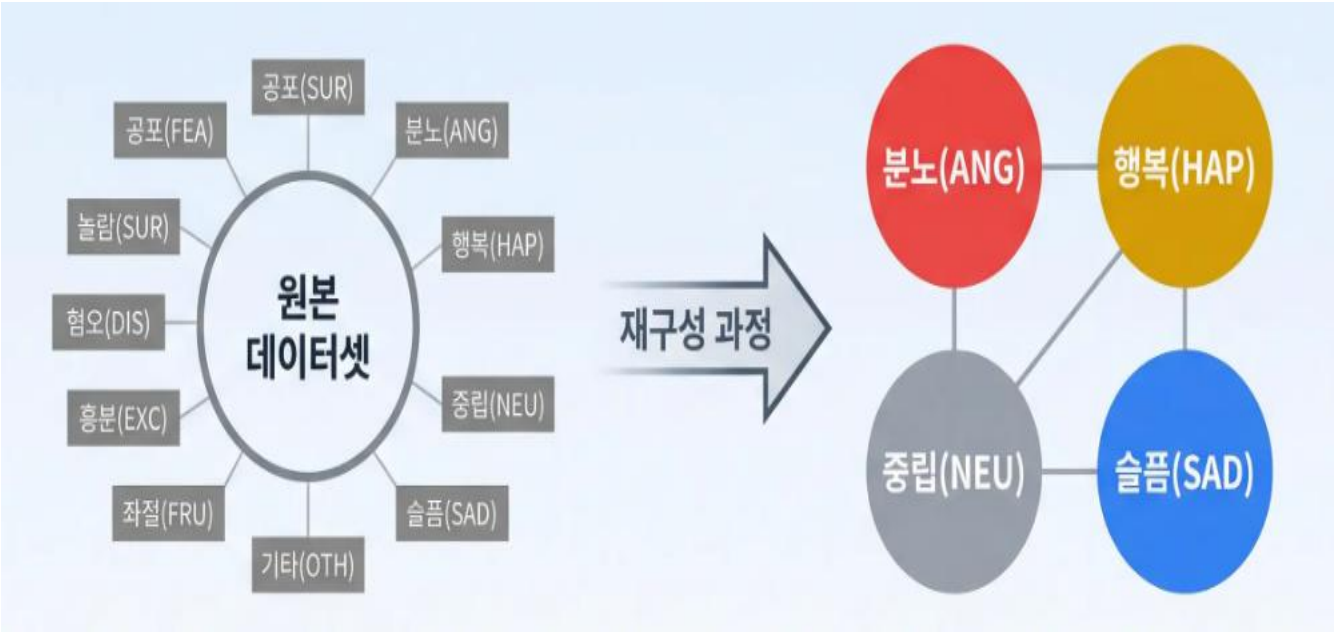

3. 문장 단위 데이터셋 활용

Huggingface에 있는 문장 단위 데이터셋 사용

4. 클래스 재구성

9개 감정 -> 4개 감정만 사용

Pretrain-Model

Text_Model

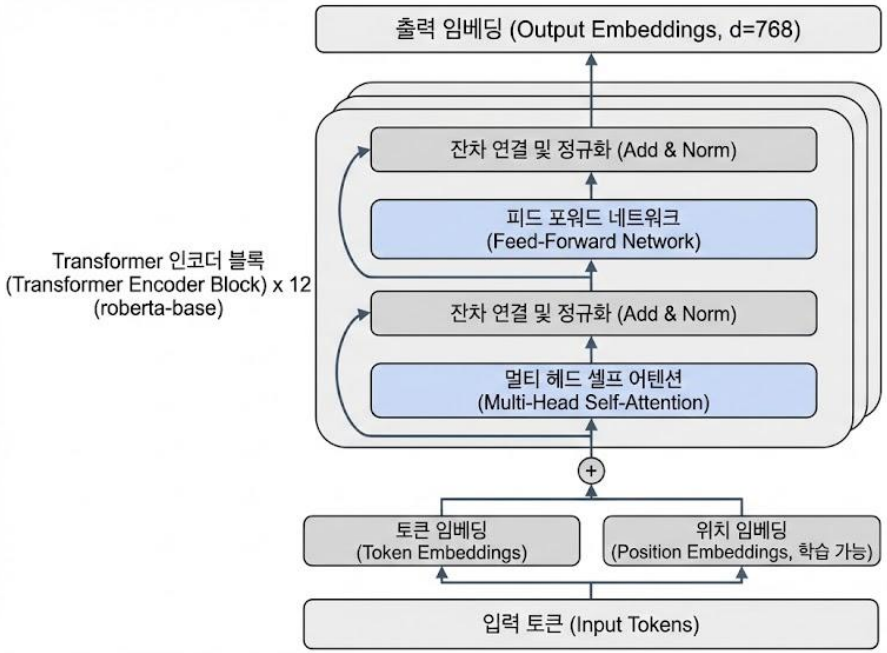

Audio Model

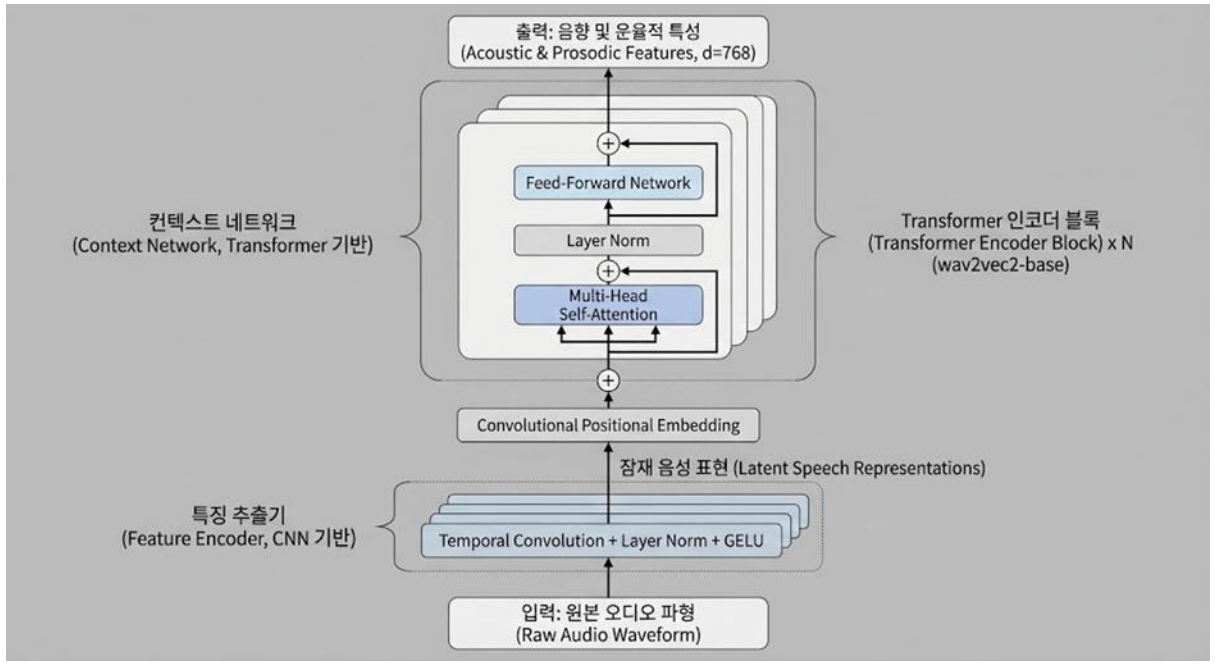

- **RobertaModel (roberta-base)**
- **차원: 768**
- **스크립트(Transcript)에서 의미론적(Semantic) 특성을 추출**

Wav2Vec2Model (facebook/wav2vec2-base-960h)
차원: 768
원본 파형(Raw Waveform)에서 음향 및 운율적 특성을 추출

Cross Attention

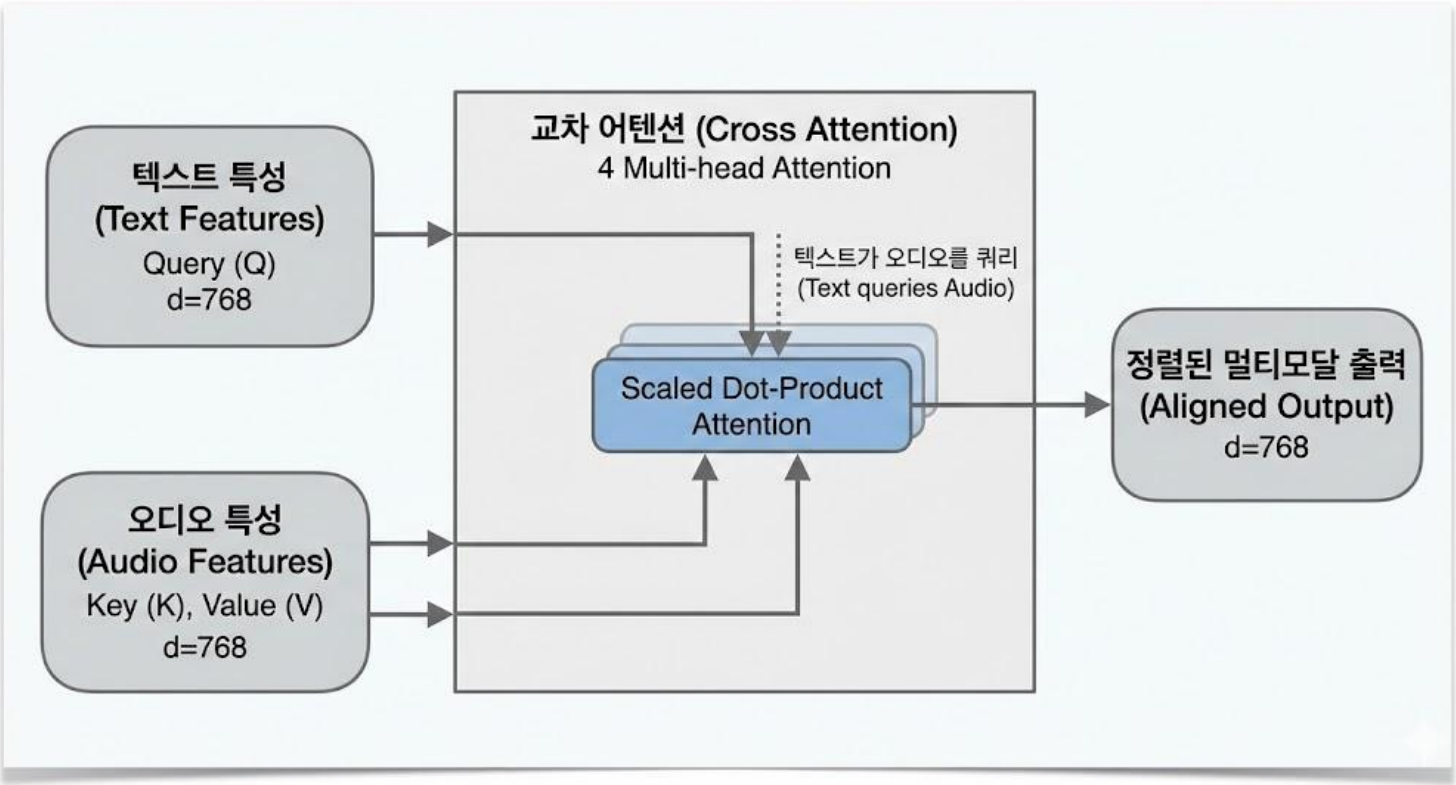

메커니즘: 텍스트가 오디오를 쿼리(Query)하는 방식
Query: 텍스트 특성
Key/Value: 오디오 특성
Heads: 4 Multi-head Attention
목적: 특정 텍스트 토큰에 해당하는 오디오 프레임을 식별하여, 운율과 의미적 내용을 효과적으로 정렬함

Pitch EDA

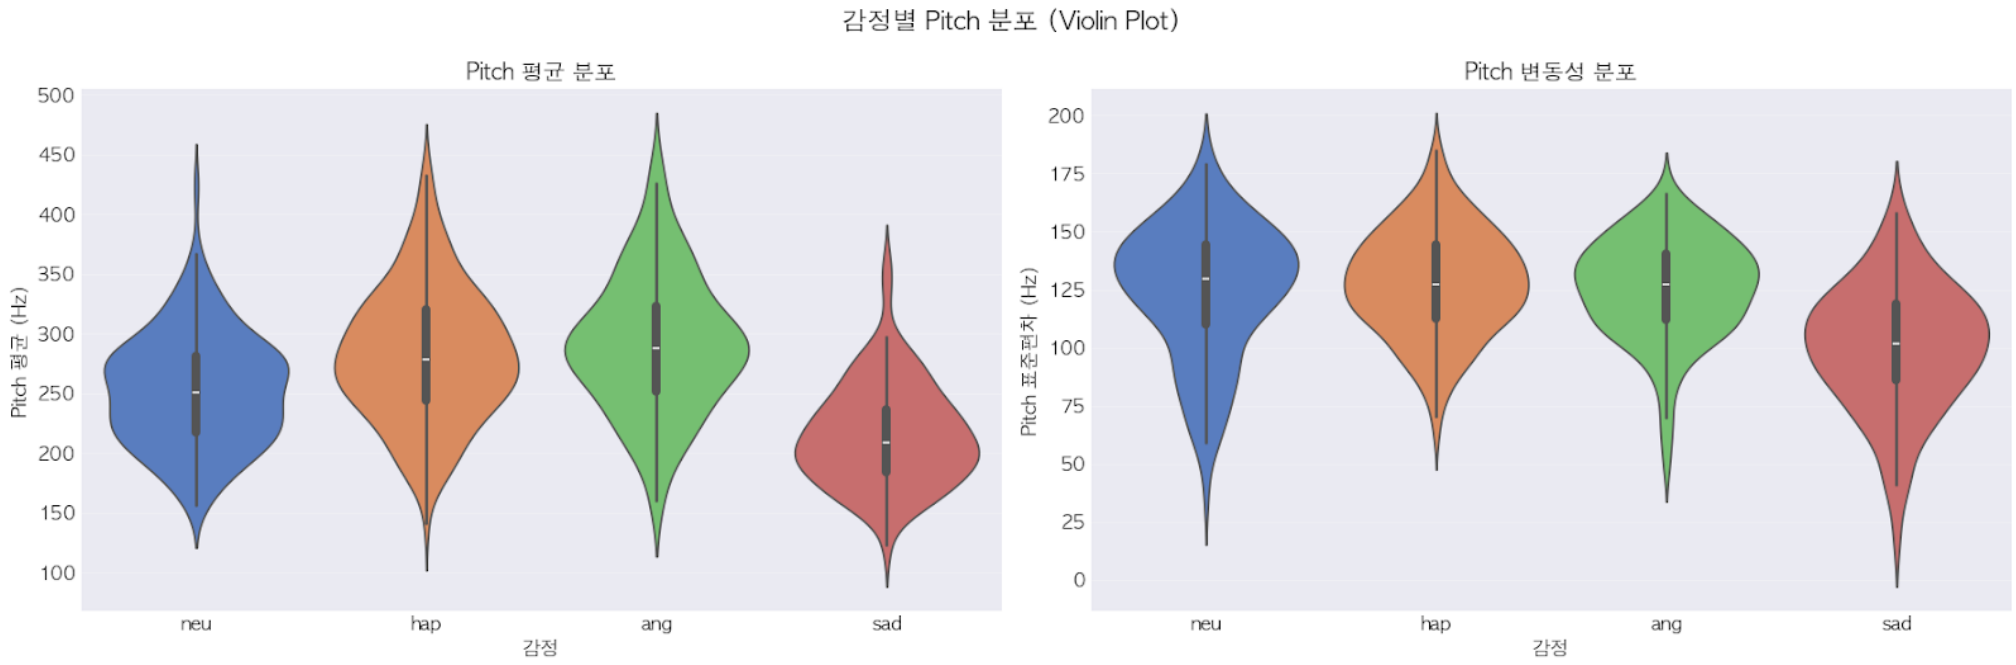

- Hap와 ang는 **avg pitch가 높고** sad은 낮음
- **Ang와 hap는 비슷한 분포를 띄어 구별이 어려움**

Energy

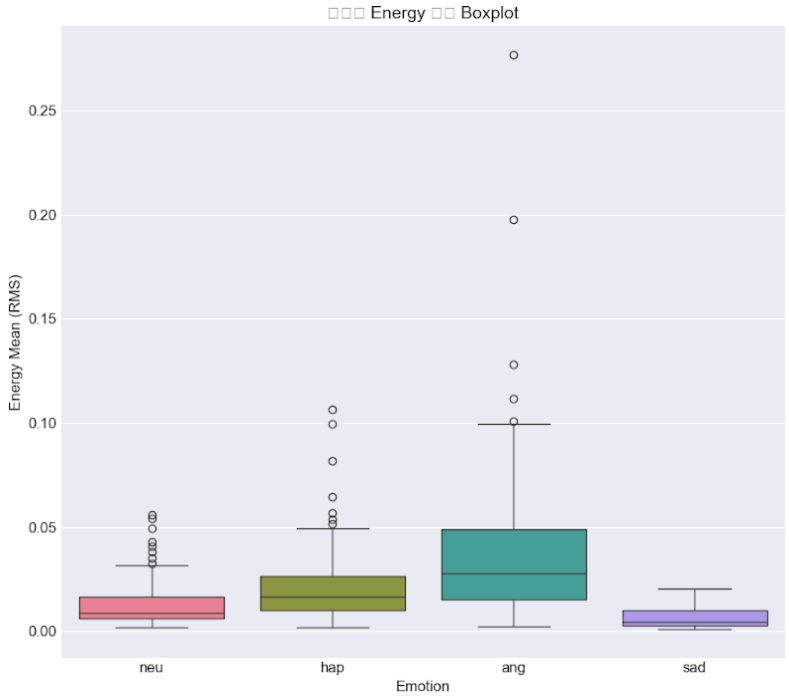

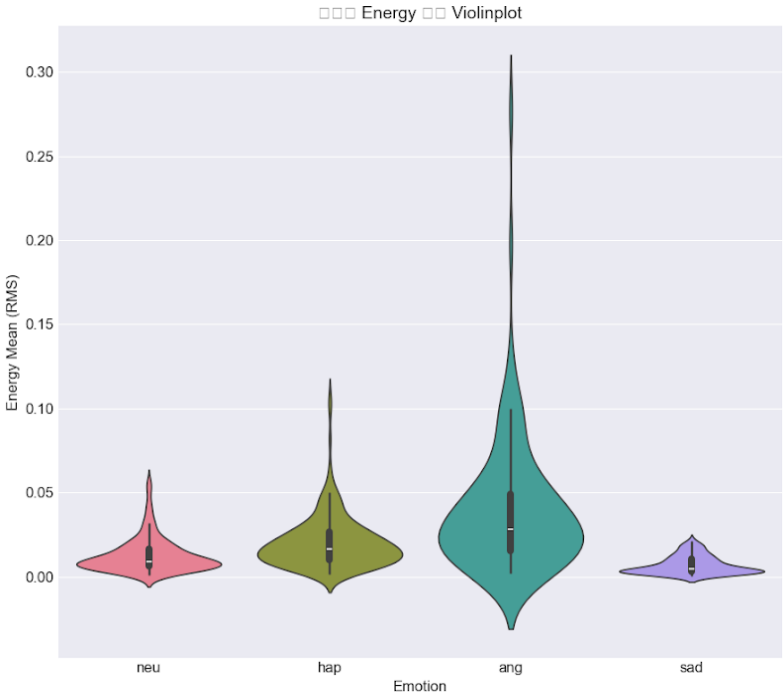

- Anger에서 가장 높고 Sad에서 가장 낮음
- 에너지는 고각성 감정의 강력한 보조 지표
- Anger는 높은 에너지와 피치를 동시에 가지므로 감정을 강하게 드러내고 Sad는 모두 낮은 경향이므로 구별이 가능함

Feature masking experiment 분석

Pitch를 masking 했을 때보다 energy를 masking했을 때 accuracy가 급격히 떨어지는 현상이 발생함

Feature masking experiment 분석(ang)

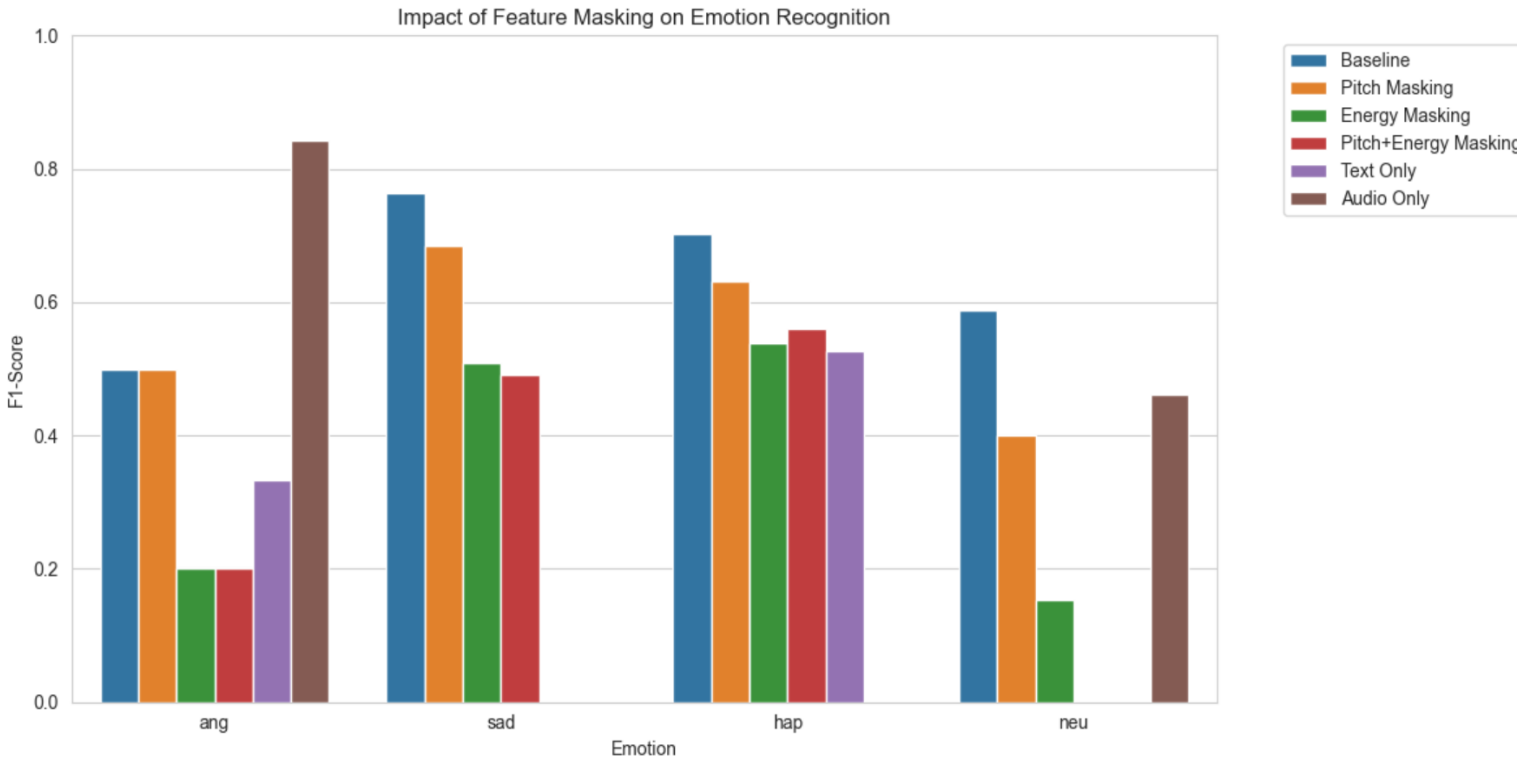

- Audio Only F1: **0.842** → Baseline(0.500)보다 훨씬 높음
- Pitch 마스킹 영향 거의 없음
  Energy 제거 시 F1: 0.200 ↓
- 음성 특징(높은 Pitch, 강한 Energy, 고주파)만으로도 명확히 구분 가능
- 텍스트는 "I don't care"처럼 오히려 판단 흐림
  → 오히려 제거했을 때 더 잘됨

Feature masking experiment 분석(hap)

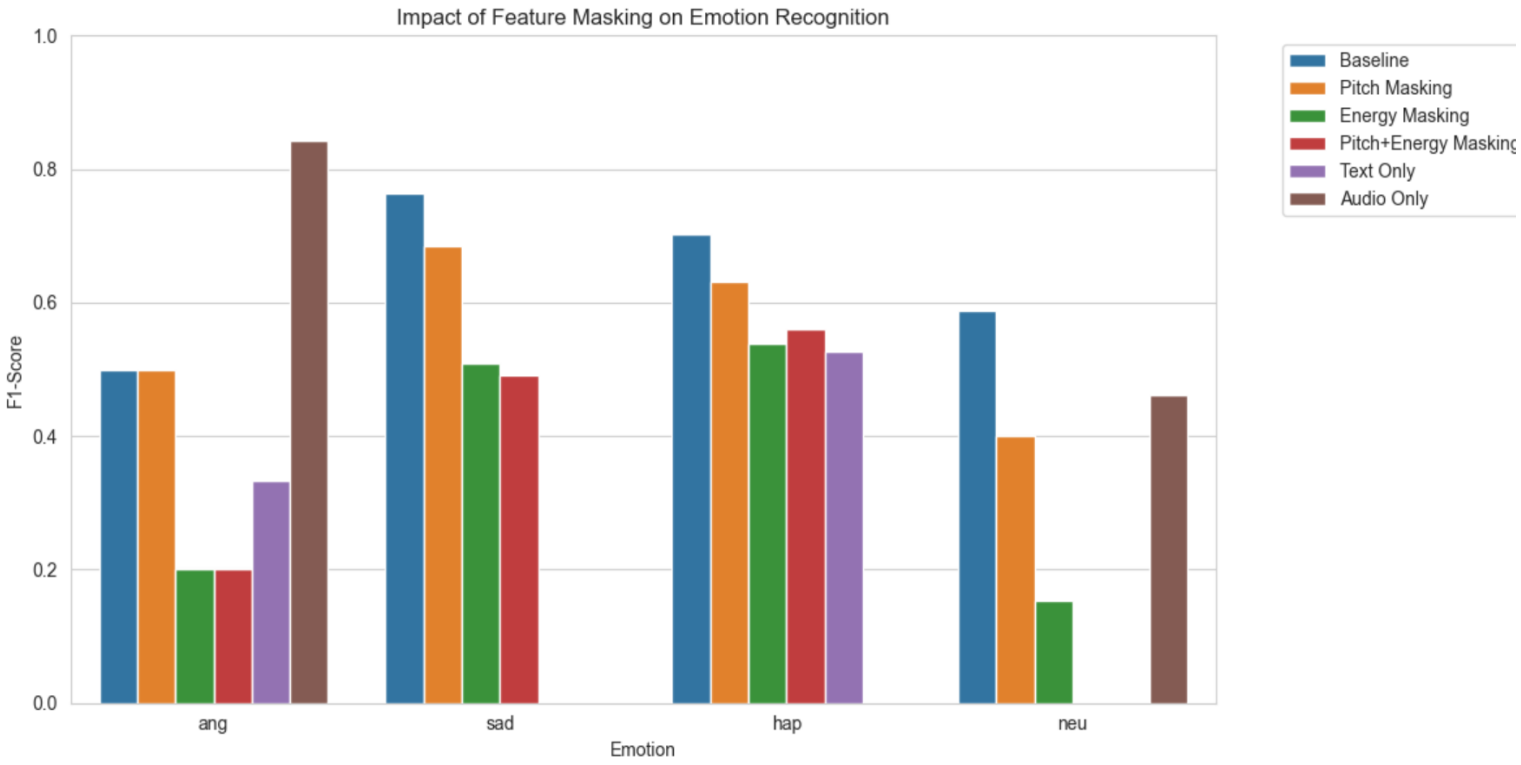

- Audio Only F1: **0.000** → 음성 정보만으로 완전 분류 실패
- Baseline F1: 0.703 → 대부분 텍스트 정보 덕분
- Pitch·Energy는 Anger와 겹쳐 혼동 쉬움
- 문장 내용(예: “That’s great”) 같은 **문맥이 핵심 단서**

Feature masking experiment 분석(sad)

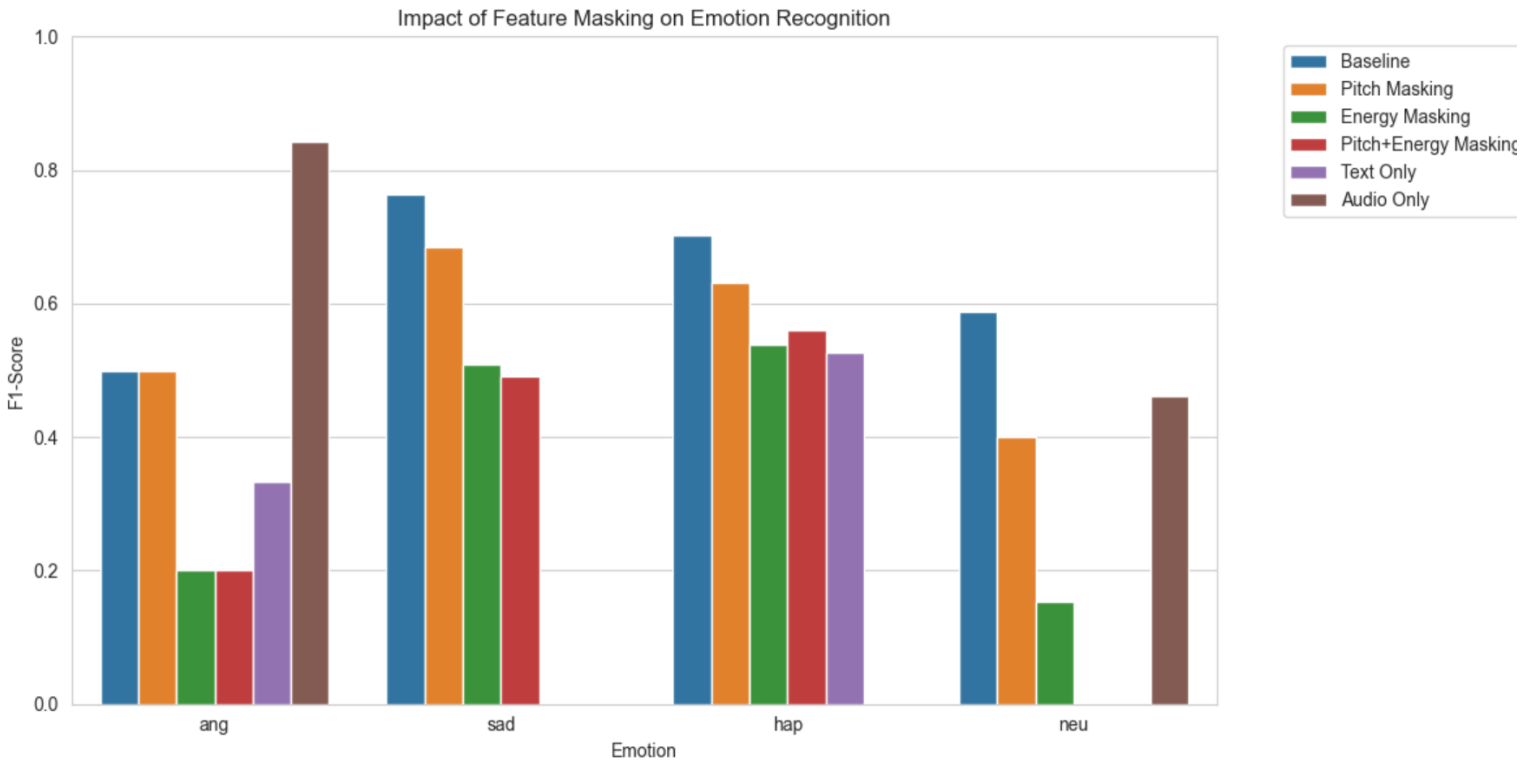

- Pitch+Energy 제거 시: F1 = **0.491**,
  Text Only & Audio Onlye: **0.000**
- Baseline F1: 0.765 → 오디오와 텍스트 모두 중요

- 낮고 평탄한 Pitch, 낮은 Energy가 결정적 단서
- 억양 없이 문장만 보면 감정 드러나지 않음

Feature masking experiment 분석(Neutral)

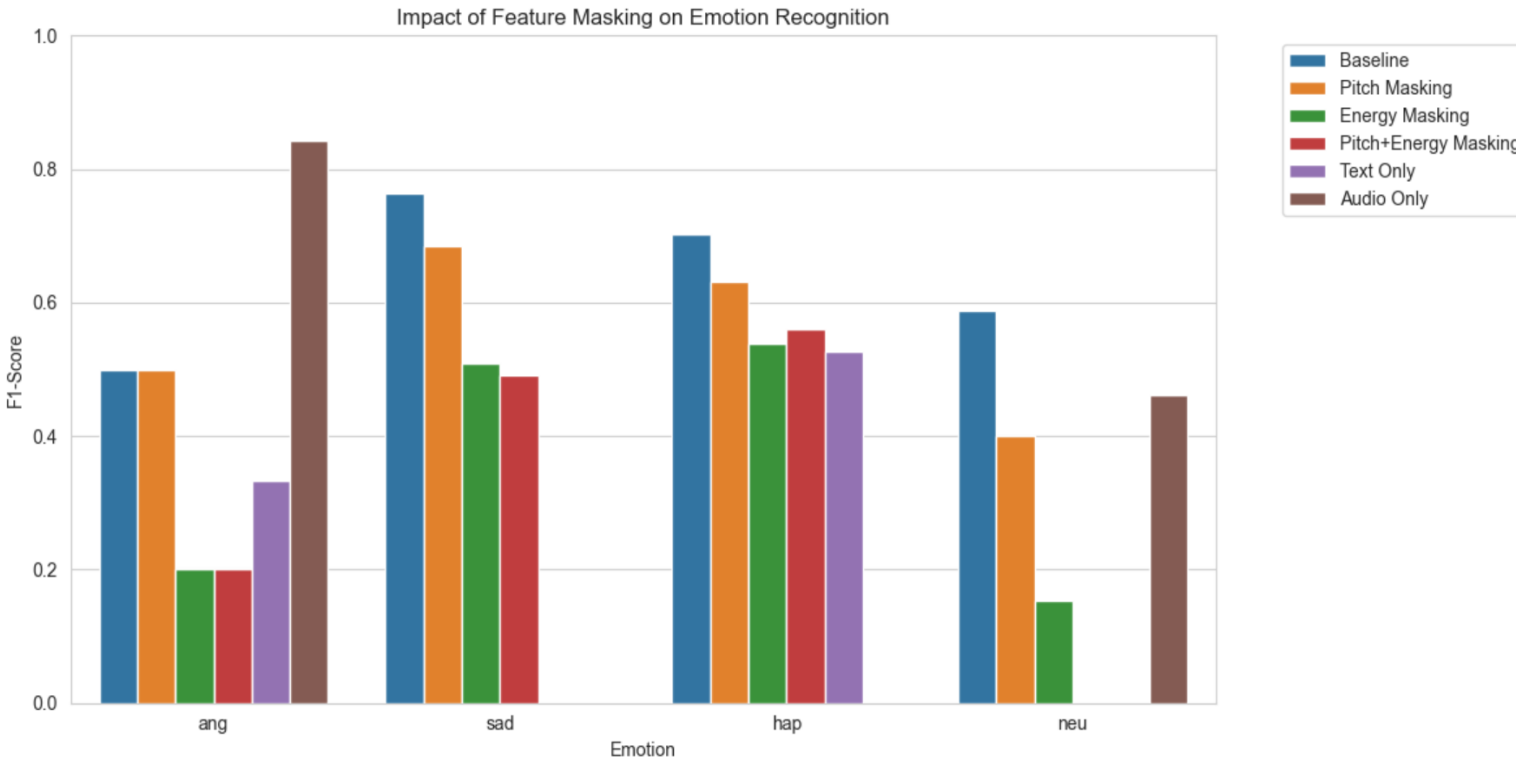

- Pitch+Energy 제거 시: F1 = **0.0**
- Text Only 조건에서도 F1 = **0.0**

- 감정 없음 자체가 특징 → 미세한 음향 정보 없으면 구별 실패
- 의미도 억양도 명확하지 않아 masking에 매우 민감함

Cross attention 분석

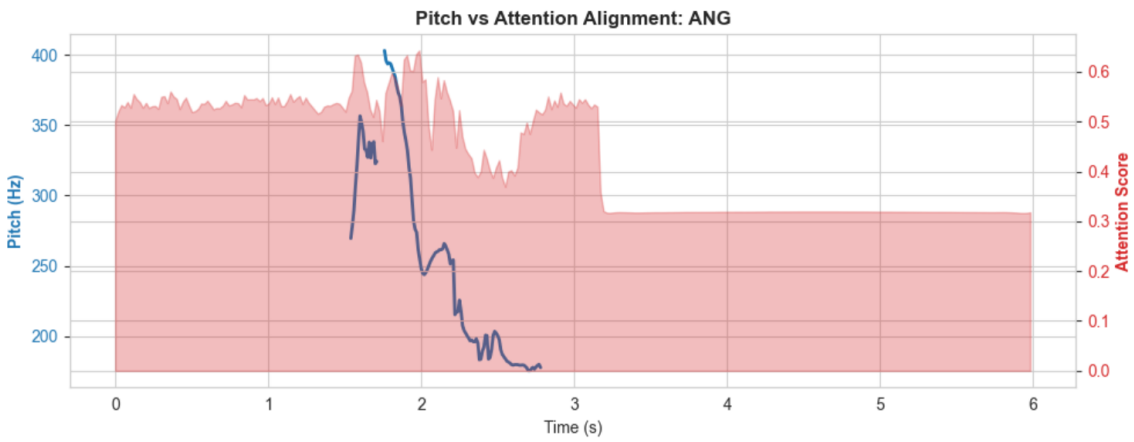

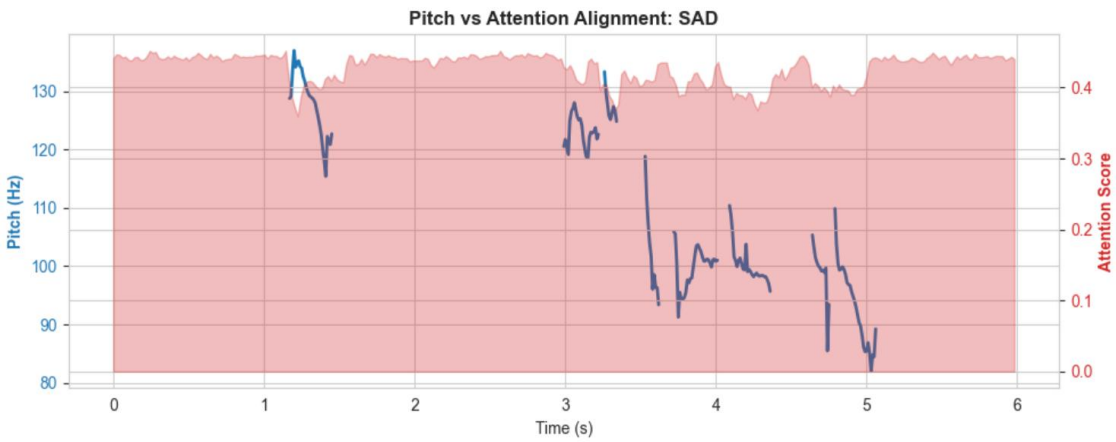

- Pitch: **200Hz 이상 급상승/급락**, 고저폭 큼
- Attention: **Pitch 변화 구간에 집중됨**
- 모델은 텍스트 토큰이 발화 중 **억양이 급변하는 오디오 프레임**을 강하게 참조
- **"I don't care."** 같은 문장이더라도 **어떻게 말했는가** (prosody)에 따라 감정이 달라짐
- **모델이 인간처럼 억양 변화를 감정 판단 기준으로 삼고 있음**

- Pitch: **낮고 평탄 (80~130Hz)**
- Attention: **전체적으로 분산**, 특정 구간 집중 없음
- 억양 변화가 없기 때문에 **모델은 고르게 오디오를 참조하거나 pause 구간에 집중함**
- 감정적 강도도 낮기 때문에 **선택적 강조 포인트가 부족**
- **모델이 슬픔을 "조용하고 평탄한 억양" 전체 흐름으로 인식함**

결과 요약

Pitch와 Energy는 감정 인식에 있어 핵심적인 음향 Feature임

	Pitch	Energy	Conclusion
Anger	높음	강함	음성 정보만으로도 정확히 분류 가능
Sad	낮고 평탄	약함	두 Feature가 없으면 감정 분류 실패
Happy& Netural	평균	중간	오디오만으로는 구분 어려워 추가 정보가 필요

Cross-Attention은 Pitch 변화에 민감하게 반응함

Anger: Pitch가 급락하는 구간 (예: 2.0~2.4초)에 Attention Score ↑ → 억양 변화가 모델 판단의 주요 단서

Sad: Pitch 변화 거의 없음 → Attention이 전체적으로 분산 → 감정이 특정 지점보단 말투 전체에 담김

인간 감정 인식 방식과의 비교

인간의 심리음향적 매커니즘

피치/ 억양 우위성

- 인간은 목소리의 Pitch를 가장 중요한 단서로 사용함

양식 의존성

- 고각성 상황(기쁨/분노)에서도 오디오(음향)만으로 감정 구분이 가능함
- 소리가 크더라도(High Energy), 운율(Prosody)의 뉘앙스를 통해 판단함

AI 모델의 실험적 메커니즘

Feature Masking

- Pitch를 지웠을 때보다 Energy를 지웠을 때 정확도가 급격히 하락함.

Cross attention

- 억양의 status에 집중
- 전체 억양 흐름을 기준으로 판단

결론 및 문헌

AI는 인간의 청각적 판단과 놀라울 정도로 유사한 특징 구조를 활용합니다.

[증거1: 피치 우위성] Scherer의 구성 요소 프로세스 모델을 뒷받침하며, 각성 감지에서 운율의 초기 역할을 나타냄

[증거2: 양식 전환] 고감정 발화에서 강력한 음향 신호가 의미 내용을 압도하는 단서 거래에 대한 심리음향적 발견과 일치함

limitation

1. Performance Limitation (성능적 한계)

- 본 연구의 모델은 텍스트와 오디오를 결합하여 준수한 성능을 보였으나, 특정 감정(Sad, Neutral)에서의 F1-Score 편차 및 오분류가 여전히 존재

- 인간 수준의 완벽한 감정 구별에는 도달하지 못함. 이는 AI가 데이터를 학습하는 방식과 인간이 직관적으로 감정을 느끼는 방식 사이에 'Feature 중요도(Priority)'의 차이가 존재하기 때문으로 추정됨.

2. Discrepancy in Feature Reliance (특성 의존도의 차이)

인간(Human): "Pitch의 '맥락적 흐름(Contour)'을 중시"

- 인간은 단순히 목소리가 높고 낮음(High/Low)을 넘어, 말의 끝을 올리거나 내리는 미세한 억양의 곡선(Intonation)을 통해 감정의 뉘앙스를 파악함.

AI 모델(Model): "Energy와 '통계적 수치(Statistics)'에 편향 가능성"

- 실험 결과, Anger 감정 분류 시 Pitch Masking보다 Energy Masking 조건에서 정확도가 더 급격히 하락함

- 이는 AI가 인간처럼 '억양의 흐름'을 이해하기보다, '소리의 강도(Energy)'나 '주파수의 물리적 절댓값'과 같은 단순하고 강렬한 특징에 더 과하게 의존하고 있음을 시사함.

3. Future Work (향후 연구 방향)

"Why Energy over Pitch?"

- AI가 왜 인간의 핵심 인지 요소인 Pitch(억양)보다 Energy(강도)에 더 민감하게 반응했는지에 대한 심층 분석 수행.

Prosody-Aware Modeling

- 단순한 물리적 특징(Acoustic Feature)을 넘어, 인간처럼 운율적 맥락(Prosodic Context)과 억양 곡선을 더 중요하게 학습하도록 모델 구조 개선