Explaining Multimodal Emotion Recognition: How Do AI Models Balance Content and Tone?

이지호 이상엽

Research objective

연구 목표	AI 감정 인식 과정에서 "언어 정보(Semantics)"와 "음향 정보(Prosody)"가 어떤 기여를 하는지 정량·정성적으로 규명하는 것
핵심 방향	• Dual-Signal Contribution 분석 텍스트 의미 vs 음향·억양 신호가 감정 판단에 미치는 영향 비교 • Feature Importance 파악 Prosody(속도·톤·강세) 및 언어적 표현이 정서 분류에 기여하는 정도 분석
Target OutCome	• 감정 인식 시 어떤 신호가 어떤 상황에서 더 유효한지 설명 가능한 인사이트 도출 • 감정 AI 설계 시 모달 우선순위·설계 방향성 제안 • XAI 관점에서 판단 근거를 구조화해 해석 가능성 확보

AI는 무엇을 기준으로 판단하는가?

" 참 잘했다. "

텍스트 분석: 100% 긍정 (칭찬)

억양 분석: 100% 부정 (비꼬는 어조)

이러한 ' **불일치(Mismatch)** ' 를 AI가 어떻게 판단하고 해결할 것인가가 본 연구의 핵심 과제입니다.

Background & Motivation

감정 인식의 핵심 입력구조에 대한 실증적 이해 필요	• 현재 감정 AI는 텍스트·음성을 조합하지만 각 신호의 영향력과 기여도가 명확히 설명되지 않음 • 이를 해석하면 AI의 추론 경로를 더 신뢰성 있게 제시 가능
Prosody의 정서 전달력 주목	• 사람 간 의사소통에서 정서 정보의 70% 이상이 비언어 신호(tone·pitch·rate) • Prosody가 중요하지만 모델 관점에서 그 기여도는 덜 연구됨
Explainable AI(XAI) 적용 시 가치가 큼	• 감정 AI는 의료·온라인 상담·고객 VOC 분석 등 신뢰 기반 도메인에서 활용도 높음 → 해석력 필수
경량 모델·RAG·디바이스 온보드 등 확장성	• 텍스트/음향 기여도를 알면 → 입력 축소·모델 경량화·도메인 최적화 설계 가능 → 서비스 적용 시 운영 효율 증가

Research Idea

멀티모달 감정 인식 모델 구축	• 텍스트(BERT) + 음성(wav2vec2 or Mel-spectrogram CNN)
XAI 기법 적용	• SHAP → 각 모달별 특징 중요도 계산 • Grad-CAM → 음성 스펙트로그램 시각화
근거 비중 비교	• 감정별로 Text/Audio 기여도 비율 산출 (예: 분노: 70% 억양 / 슬픔: 55% 텍스트)

Data set: MELD (Multimodal EmotionLines Dataset)
-Modal: Text, Audio
-Emotion class: 7(Anger, Disgust, Fear, Joy, Neutral, Sadness, Surprise)

Text Encoder: DistilBERT-base-uncased(hugging face)
-대사 내용을 입력을 받아 **단어 의미 기반 감정 단서** 추출

Audio Encoder:Wav2Vec2-base (Hugging Face)
-억양, 속도, 강세 등 **감정적 음성 특징** 추출

Model structure

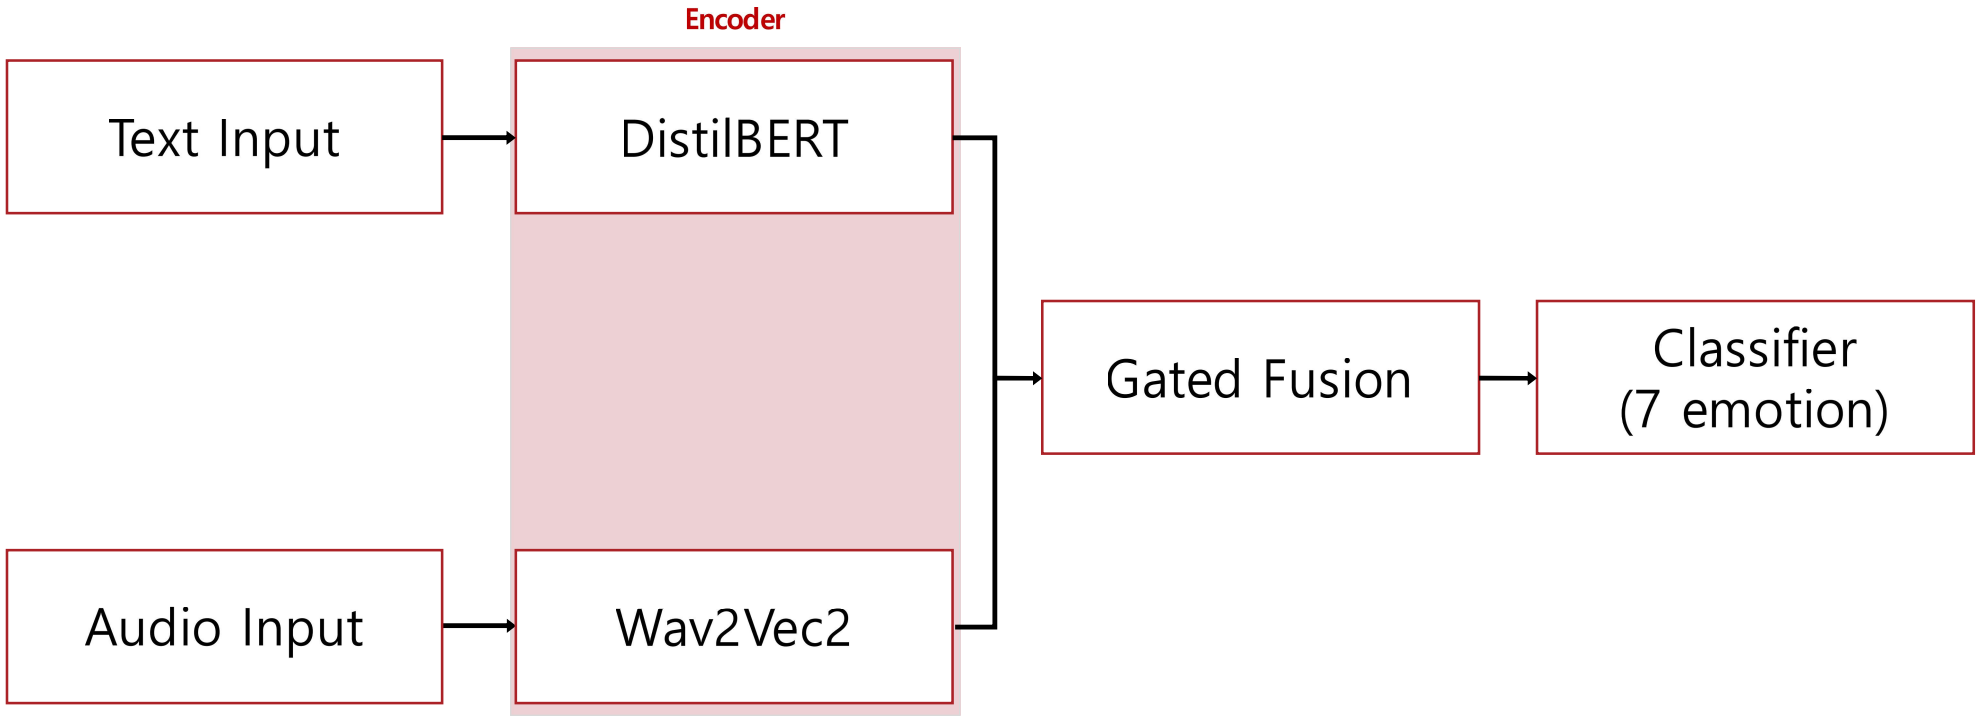

Masking experiment

텍스트 또는 오디오를 각각 제거(masking)했을 때 감정 예측 확률이 얼마나 변하는가?
어떤 feature가 더 중요하게 감정을 추출할 때 중요하게 적용되는가?

실험	입력 구성	의미
Text Masking	[MASK] or 빈 문장	말의 내용 제거
Audio Masking	무음 or 노이즈 대체	억양 제거
비교	예측 확률 변화(Δ)	각 모달의 중요도

예시 기대 결과

텍스트 SHAP: “정말”, “미쳤다” → 분노에 높은 기여
음성 Grad-CAM: 고주파(2–4 kHz), 급격한 pitch 상승 → 분노 신호
기여도 비교:

- 분노: Audio 72% / Text 28%
- 슬픔: Audio 55% / Text 45%
- 행복: Text 60% / Audio 40%

결론	AI는 감정 종류에 따라 “내용 vs 억양” 의존도가 다르다. 이는 인간의 감정 인식 패턴과 유사한지 비교 가능.

Expected Results & Visualization

분야	기대효과
AI Explainability	블랙박스 감정 인식 모델의 내부 판단 근거를 해석
Human Alignment	인간 감정 판단 구조와 AI의 근거 비교
모델 개선	특정 감정에 대한 모달 편향(예: 음성 과의존) 보정 가능
응용 가능성	감정 챗봇, 상담 분석, 감정 TTS, 인간-로봇 상호작용 개선